

소재정보학 최신 연구 동향

물성 예측부터 자율실험실까지


UST 소재정보학 (Materials Informatics)

이예리 | 한국화학연구원 디지털화학연구센터

오늘 강의 내용

	내용
1	물성 예측 모델 — GNN, 범용 원자간 포텐셜, 벤치마크, LLM
2	소재 스크리닝과 생성 모델 — 대규모 탐색, 역설계, 능동학습
3	문헌 데이터 활용 — 텍스트 마이닝, LLM 기반 정보 추출
4	자율실험실과 AI 에이전트


소재정보학 연구 과정



- 데이터: 계산 DB (MP, OQMD, AFLOW), 실험 데이터, 문헌
- 표현: 조성 descriptor, 결정 구조, 그래프, 텍스트
- 모델: RF, GBM, 신경망 → GNN, 범용 포텐셜, LLM 중심으로
- 최근에는 각 단계를 따로 개선하기보다 전체 과정을 하나로 연결하는 연구가 늘고 있음

소재 AI 연구의 흐름

Foundation models for materials discovery – current state and future directions



- 규칙 기반 → 특징(feature) 기반 ML → 딥러닝 → 파운데이션 모델
- 파운데이션 모델: 대량의 데이터로 사전학습한 후 여러 과제에 맞게 미세조정해서 사용
- 소재 분야에서는 범용 원자간 포텐셜, 소재 특화 언어모델, 생성 모델 등이 해당

생각해 볼 질문

AI가 새로운 소재를 "발견"했다는 것은 무엇을 의미하는가?

- 계산상 안정한 구조를 예측한 것?
- 실제로 합성에 성공한 것?
- 원하는 성능을 가진 소자로 구현한 것?

Part 1

물성 예측 모델

1. 물성 예측 모델

- 2. 소재 스크리닝과 생성 모델
- 3. 문헌 데이터 활용
- 4. 자율실험실과 AI 에이전트
- 5. 정리

물성 예측 모델의 기본 구조

$$\text{물성} = f(\text{소재의 표현})$$

입력 (표현)

- 조성: 원소 특성 통계 (Magpie 등)
- 구조: 결정 그래프, 원자 환경
- 텍스트: 화학식, SMILES, 문장

출력

- 형성 에너지, 밴드갭, 탄성 계수 등
- 에너지·힘·응력 (원자간 포텐셜)
- 안정성 (convex hull 기준)


모델

- RF, GBM: 데이터가 적을 때 유리
- GNN: 구조 정보를 직접 학습
- LLM: 텍스트 기반 입출력

같은 데이터라도 어떤 표현을 쓰느냐에 따라 성능과 일반화 능력이 크게 달라짐

Matbench: 물성 예측 벤치마크

Benchmarking materials property prediction methods: the Matbench test set and Automatminer



- 13개 물성 예측 과제로 구성
 - 안정성, 전자·기계·광학·열 특성
 - 데이터 수 수백 ~ 13만여 개
 - 조성만 주어지는 과제 / 구조가 주어지는 과제
- 동일한 데이터 분할과 평가 지표로 모델 비교
- 기준 모델로 Automatminer(AutoML) 제공

데이터가 적은 과제는 전통 ML, 많은 과제는 GNN이 우세


모델 성능 평가 시 주의할 점

- Data leakage
 - 비슷한 소재(같은 조성의 다른 구조 등)가 학습·테스트 세트에 함께 들어가는 경우
 - 테스트 성능이 실제보다 높게 나옴
- 보간(interpolation)과 외삽(extrapolation)
 - 무작위 분할은 주로 보간 성능을 평가
 - 새로운 화학계 탐색은 외삽 문제 → LOCO-CV 등으로 평가 (Meredig et al., 2018)
- 평가 지표
 - 회귀: MAE, RMSE, R^2 / 분류: precision, recall
 - 소재 탐색이 목적이면 실제 성공 비율(hit rate)이 더 중요

테스트 점수가 높다고 새로운 소재를 잘 찾는 것은 아님

ALIGNN


Atomistic Line Graph Neural Network for improved materials property predictions



- 원자 그래프(노드: 원자, 엣지: 결합 거리)에 line graph(노드: 결합, 엣지: 결합각) 추가
- 두 그래프에서 번갈아 message passing → 결합각 정보까지 반영
- MP 2개 과제, JARVIS-DFT 29개 과제 중 28개에서 CGCNN보다 낮은 오차

M3GNet: 범용 원자간 포텐셜


A universal graph deep learning interatomic potential for the periodic table



- 특정 물성 대신 에너지(E)를 학습하고, 미분으로 힘(f)과 응력(σ) 계산
- Materials Project 구조 완화 데이터로 학습, 89개 원소 포함
- DFT 없이 구조 완화, 분자동역학 계산 가능 → 범용 MLIP의 대표적인 초기 모델

CHGNet


CHGNet as a pretrained universal neural network potential for charge-informed atomistic modelling



- MPtrj 데이터(약 158만 개 구조, 약 14.6만 개 화합물)로 사전학습
- 원자 자기모멘트를 함께 학습 → 전하 상태(산화수) 정보 반영
- 원자, 결합, 결합각 그래프 사용
- 응용: 배터리 양극재 상전이, Li 확산 등
- 코드 공개 (pip install chgnet)

Matbench Discovery


A framework to evaluate machine learning crystal stability predictions



- MP로 학습한 모델로 새로운 가상 구조(WBM)의 안정성 예측
- relax 전 초기 구조를 입력으로 사용
→ 실제 탐색 상황과 같은 조건
- 에너지 오차보다 안정/불안정 분류 성능을 중점적으로 평가
- 온라인 리더보드 운영

Matbench Discovery: 모델별 비교

A framework to evaluate machine learning crystal stability predictions




- 붉은 영역: 예측 오차 때문에 안정성 판정이 바뀔 수 있는 구간
- Convex hull 근처(0 eV/atom)의 오차가 특히 중요
- 범용 원자간 포텐셜(eqV2, ORB, SevenNet, MACE 등)이 상위권

형성 에너지 MAE가 낮아도 안정성 분류 성능은 다를 수 있음

LLM을 이용한 물성 예측


Leveraging large language models for predictive chemistry



- GPT-3를 질문-답변 형태의 화학 데이터로 fine-tuning(예: "이 분자의 전이 파장은?" → "낮음")
- 분류, 회귀, 역설계를 같은 방식으로 처리
- 데이터가 적은 분류 과제에서 기존 ML 모델과 비슷한 수준 (항상 우세한 것은 아님)

MatterChat: 멀티모달 LLM

A multimodal large language model for materials science



- 결정 구조와 텍스트를 함께 입력받는 LLM
- 사전학습된 원자간 포텐셜(CHGNet 또는 MACE-MP-0) + LLM(Mistral 7B) 연결
 - 두 모델은 고정하고 중간 연결 모듈만 학습
- 물성 예측과 자연어 질의응답을 하나의 모델에서 수행
- MPtrj 기반 약 14만 3천 개 구조로 학습

Part 1 정리

구분	대표 연구	특징	한계
특징 기반 ML	Magpie, Automatminer	원소 특성 통계로 조성 표현	구조 정보 부족
그래프 신경망	CGCNN, ALIGNN	결정 구조를 그래프로 학습	물성마다 따로 학습
범용 원자간 포텐셜	M3GNet, CHGNet	에너지·힘 학습, 시뮬레이션 가능	학습 데이터 범위에 의존
언어모델	GPT-3 미세조정, MatterChat	텍스트 입출력, 구조+언어 결합	수치 정확도, 검증

- 평가 방식도 무작위 분할 기반 벤치마크(Matbench) → 실제 탐색 상황 기반(Matbench Discovery)으로 변화

Part 2

소재 스크리닝과 생성 모델

1. 물성 예측 모델
- 2. 소재 스크리닝과 생성 모델**
3. 문헌 데이터 활용
4. 자율실험실과 AI 에이전트
5. 정리 및 토론


가상 스크리닝 (virtual screening)



- 아래 단계로 갈수록 비용은 커지고 후보 수는 줄어듦
- ML은 비싼 계산·실험으로 보낼 후보를 고르는 역할
- 능동학습: 계산·실험 결과를 다시 모델 학습에 반영

GNoME

Scaling deep learning for materials discovery



- 구조 기반, 조성 기반 두 가지 방식으로 후보 생성
- GNN으로 안정성 예측 → DFT 계산 → 결과를 다시 학습 (능동학습 반복)
- 약 220만 개의 안정 구조 예측
 - 그중 약 38만 개가 새로운 convex hull 위의 구조
- 학습 데이터가 늘수록 예측 오차가 꾸준히 감소 (그림 e)


GNoME 결과에 대한 논의

- 계산상 안정성
 - DFT(0 K) 기준이며 온도, 무질서, 결함 효과는 고려되지 않음
- 새로움과 유용성
 - 비슷한 양이온(란타넘족끼리, Zr/Hf 등)을 인위적으로 정렬해 이미 알려진 구조를 새 구조처럼 보이게 한 경우가 많다는 지적 (Cheetham & Seshadri, 2024)
 - "소재"라고 부르려면 쓸모 있는 기능이 있어야 함
- 합성 가능성
 - 안정하다고 해서 반드시 합성할 수 있는 것은 아님

대규모 예측은 탐색 범위를 넓혀주지만, 최종 검증은 결국 실험

정방향 설계와 역설계

정방향 (forward)




역설계 (inverse design)



- 정방향: 후보를 먼저 만들고 물성을 예측해 선별 → 후보군 밖의 소재는 찾을 수 없음
- 역설계: 목표 물성을 조건으로 구조를 직접 생성 (VAE, GAN, diffusion model 등)
- 생성 모델 평가: 안정성(Stable), 고유성(Unique), 새로움(Novel) → SUN 비율

MatterGen: 확산 모델 기반 결정 구조 생성


A generative model for inorganic materials design



- 원자 종류(A), 좌표(X), 격자(L)에 노이즈를 추가했다가 제거하는 과정을 학습
- 사전학습 후 adapter 모듈로 미세조정 → 화학계, 공간군, 물성 조건을 주고 생성
- 기존 생성 모델 대비 새롭고 안정한 구조의 비율이 2배 이상


MatterGen: 실험 검증

A generative model for inorganic materials design



- 목표 체적 탄성률(bulk modulus)을 조건으로 구조 생성
- 생성된 TaCr_2O_6 를 실제로 합성하고 XRD로 구조 확인
 - 실제 합성물은 Ta/Cr 자리가 무질서한 구조
- 나노인덴테이션으로 추정한 체적 탄성률 최대 169 GPa (목표 200 GPa)
 - 합성 시도 4건 중 1건 성공



능동학습과 베이지안 최적화



- Surrogate model: 적은 데이터로 목적함수를 근사 (예: 가우시안 프로세스)
 - 예측값과 함께 불확실성도 제공
- Acquisition function: 다음에 실험할 조건을 선택하는 기준 (EI, UCB 등)
- Exploration(불확실한 영역 탐색)과 exploitation(좋은 영역 집중)의 균형이 중요
- 적은 실험 횟수로 최적 조건을 찾을 수 있어 자율실험실에서 가장 많이 쓰이는 방법

능동학습과 베이지안 최적화, 무엇이 다른가

Same surrogate (Gaussian process), different acquisition function $\rightarrow$ different experiments




	능동학습 (AL)	베이지안 최적화 (BO)
목표	전 구간 모델 정확도	최적 조건 빨리 찾기
다음 실험	$\sigma(x)$ 최대	EI(x) 최대 (μ 와 σ 모두)
실험 분포	전체에 고르게	최적점 근처에 집중

목적이 “모델”이면 AL, “최적 조건”이면 BO

페로브스카이트 페루프 연구 (1)


Autonomous closed-loop framework for reproducible perovskite solar cells



- 계면 passivation 분자를 능동학습으로 탐색
- 양자화학 계산 descriptor + symbolic regression으로 PCE 예측 모델 구성
- 자동 소자 제작 플랫폼에서 베이지안 최적화로 공정 조건 최적화
- 소재 탐색과 소자 제작을 하나의 루프로 연결

페로브스카이트 페루프 연구 (2)


Autonomous closed-loop framework for reproducible perovskite solar cells



- Symbolic regression으로 PCE를 일함수, HOMO/LUMO 등의 식으로 표현
- 후보 분자 16,158 $\rightarrow$ 1,154 $\rightarrow$ 57개로 압축
- 최종 선정된 5ANI: PCE 27.22% (인증 27.18%)
- 21.4 cm² 미니모듈 23.49%
- 효율 편차(CV)가 수작업 4.99% $\rightarrow$ 자동 제작 1.05%로 감소

정공수송재료(HTM) 역설계

Inverse design workflow discovers hole-transport materials tailored for perovskite solar cells




- 가상 분자 약 100만 개 → 13,000개 계산 → 101개 합성·소자 평가
- 자동 고속 합성·정제·측정으로 실험 데이터 확보
- DFT descriptor + 실험 데이터로 가우시안 프로세스 모델 학습, 베이지안 최적화로 48개 추가 제안·검증
- 최적 소재: 소자 최적화 후 PCE 26.2% (인증 25.9%), 같은 조건 MeO-2PACz 24.6%

계산 데이터만이 아니라 실험 데이터로 학습했다는 점이 특징

실패한 실험 데이터의 활용

Machine-learning-assisted materials discovery using failed experiments



- 연구 노트에 기록된 실패한 반응까지 데이터베이스화
- SVM으로 결정화 성공 여부 예측
- 모델 추천 반응 성공률 89% (기존 경험 규칙 78%)
- 학습된 모델에서 결정 트리를 뽑아 화학적 가설 도출

논문에는 성공한 결과만 실리기 때문에 실패 데이터는 구하기 어려움

Part 2 정리

접근	대표 연구	방법	남은 과제
대규모 스크리닝	GNoME (2023)	GNN + DFT 능동학습	합성 가능성, 유용성
생성 모델	MatterGen (2025)	조건부 확산 모델	실험 검증 확대
실험 데이터 기반 역설계	HTM (Science 2024)	자동 합성 + ML	데이터 규모
페루프 최적화	5ANI (Nature 2026)	능동학습 + BO + 자동 제작	다른 소재계로 확장

- 계산 중심의 탐색에서 실험 데이터를 포함하는 페루프 방식으로 옮겨가는 추세

Part 3

문헌 데이터 활용

1. 물성 예측 모델
2. 소재 스크리닝과 생성 모델
- 3. 문헌 데이터 활용**
4. 자율실험실과 AI 에이전트
5. 정리


왜 문헌 데이터인가

- 실험 데이터의 대부분은 논문 본문, 표, 그림에 흩어져 있음
- 공개 DB는 주로 계산 데이터 → 합성 조건, 공정, 소자 데이터는 문헌에서 찾아야 함

시기	방법	예
2016~	규칙·사전 기반 추출	ChemDataExtractor
2019~	단어 임베딩	word2vec (Tshitoyan et al.)
2021~	소재 특화 언어모델	MatBERT, MatSciBERT
2023~	LLM 기반 추출	미세조정, 프롬프트 설계
2025~	에이전트, 멀티모달	표·그림 정보까지 추출

논문 초록을 이용한 소재 예측 (1)


Unsupervised word embeddings capture latent knowledge from materials science literature



- 초록 약 330만 편을 모아 그중 관련 있는 약 150만 편으로 word2vec 학습 (라벨 불필요)
- 단어 벡터 사이의 관계에 화학 지식이 반영됨: $\text{Ni} - \text{NiO} \approx \text{Zr} - \text{ZrO}_2$ (산화물 관계), BCC·FCC·HCP 구조 관계

논문 초록을 이용한 소재 예측 (2)


Unsupervised word embeddings capture latent knowledge from materials science literature



- 과거 특정 시점까지의 초록만으로 학습한 뒤 "thermoelectric"과 가까운 소재 순위 계산
- 상위 50개 예측이 5년 안에 열전소재로 연구될 확률이 무작위 선택의 약 8배 (예: CuGaTe₂는 2012년 보고 4년 전에 상위 5위 안)

합성 레시피 텍스트 마이닝


Text-mined dataset of inorganic materials synthesis recipes



- 논문 수집 → 합성 문단 분류 → 타깃 물질, 전구체, 공정, 조건 추출
- 53,538개 문단에서 고상합성 레시피 19,488건 구축
- 합성 조건 예측 연구의 기반 데이터
 - 이후 A-Lab의 레시피 제안에도 활용

LLM 미세조정을 통한 정보 추출


Structured information extraction from scientific text with large language models



- 개체명 인식과 관계 추출을 한 번에 수행하고 결과를 JSON 형식으로 출력
- 소수의 수작업 주석으로 중간 모델 학습 → 모델이 초안 작성, 사람이 수정 → 반복 (최종 400~650쌍)
- 도핑, MOF, 일반 소재 정보 추출에 적용

ChatExtract: 프롬프트 기반 정보 추출


Extracting accurate materials data from research papers with conversational language models



- 별도 학습 없이 대화형 LLM과 정해진 프롬프트 흐름만 사용
- 데이터 포함 여부 확인 → 값 추출 → 추가 질문으로 결과를 다시 검증
- 불확실하면 "없음"으로 답하게 해서 잘못된 추출(hallucination) 감소
- 체적 탄성률 데이터 추출에서 정밀도 90.8%, 재현율 87.7% (GPT-4)

The Perovskite Database

An open-access database and analysis tool for perovskite solar cells based on the FAIR data principles



- 문헌에서 약 4만 2천 개 소자 데이터를 수작업으로 수집
- 조성, 소자 구조, 공정, 성능을 표준 형식으로 정리
- 전체 소자의 효율은 기록 효율보다 훨씬 낮은 쪽에 분포 (그림 a)
- 용매, 조성 등 연구 경향의 변화도 확인 가능

문헌 데이터 활용 시 주의할 점

- 잘못된 추출 (hallucination)
 - 없는 값 생성, 단위·측정 조건 누락, 표와 그림 값 혼동
 - 원문 근거 문장을 함께 저장하고, 일부는 사람이 직접 검수
- 출판 편향
 - 성공한 결과 위주로 보고됨 → 모델이 낙관적으로 학습될 수 있음
- 표준화 문제
 - 같은 물성이라도 측정법·정의가 다르고, 소자 구조·공정 표기도 제각각
 - 스키마와 온톨로지 설계가 필요
- FAIR 원칙: Findable, Accessible, Interoperable, Reusable

Part 3 정리

방법	대표 연구	할 수 있게 된 것
단어 임베딩	Tshitoyan (2019)	라벨 없이 문헌 속 지식 추출, 후보 추천
텍스트 마이닝	Kononova (2019)	합성 레시피의 대규모 구조화
LLM 미세조정	Dagdelen (2024)	복잡한 관계를 정해진 형식(JSON)으로 추출
프롬프트 설계	ChatExtract (2024)	코딩 없이 높은 정확도로 추출
커뮤니티 DB	Perovskite Database (2022)	분야 전체 데이터의 표준화 및 공개


Part 4

자율실험실과 AI 에이전트

1. 물성 예측 모델
2. 소재 스크리닝과 생성 모델
3. 문헌 데이터 활용
- 4. 자율실험실과 AI 에이전트**
5. 정리

A-Lab: 무기 소재 자율 합성


An autonomous laboratory for the accelerated synthesis of inorganic materials



- 합성 대상: MP와 Google DeepMind 계산에서 선정한 공기 중 안정한 신규 화합물
- 문헌 기반 모델이 전구체와 온도 제안 → 로봇 합성 → XRD 분석, 실패하면 열역학 기반 능동학습으로 레시피 수정

A-Lab 결과와 이후 논의

An autonomous laboratory for the accelerated synthesis of inorganic materials




- 17일간 연속 운영, 목표 물질 57개 중 36개 합성 (정정 후 기준)
- 실패 원인: 느린 반응 속도, 전구체 휘발, 비정질화 등
- 자동 XRD 분석의 정확성과 신규성 판단에 대한 문제 제기 (Leeman et al., 2024)
 - 처음 발표 당시 58개 중 41개 → 정정

자동화된 결과 해석의 검증이 가장 어려운 부분

Coscientist


Autonomous chemical research with large language models



- GPT-4 기반 planner가 웹 검색, 문서 검색, 코드 실행, 실험 장비를 도구로 활용
- 장비 API 문서를 읽고 액체 핸들러 제어 코드를 직접 작성, Suzuki-Sonogashira 반응을 설계·실행

ChemCrow



Augmenting large language models with chemistry tools



- 추론(Thought) → 도구 선택(Action) → 결과 확인(Observation) 반복
- 분자, 반응, 안전성 관련 전문 도구 18개 연결
- 로봇 합성 플랫폼(RoboRXN)으로 방충제(DEET)와 thiourea 유기촉매 3종 합성
- 위험 물질 확인 등 안전 관련 도구 포함

이동형 로봇을 이용한 자율 합성

Autonomous mobile robots for exploratory synthetic chemistry



- 이동형 로봇이 합성 장비, NMR, 질량 분석기 사이에서 시료 운반
- 기존 실험 장비를 그대로 사용 → 실험실 구조 변경 최소화
- NMR과 MS 결과를 종합해서 다음 실험 결정
- 결과가 정해져 있지 않은 탐색형 실험 (반응 탐색, 초분자 합성)에 적용

자율실험실의 발전 단계

단계	내용	예
자동화	정해진 레시피를 로봇이 반복 수행	자동 스프인코팅 장비
페루프 최적화	측정 결과를 바탕으로 다음 조건을 자동 결정 (BO 등)	5ANI 소자 공정 최적화
자율 탐색	가설 수립, 실험 계획, 결과 해석까지 AI가 수행	A-Lab, Coscientist

- KRICT KMAP: 페로브스카이트 다층 소자 자동 제작 장비 (국내 기술로 개발)
 - 현재 자동화 단계이며, 자율화를 목표로 개발 진행 중
 - solar.chemdx 데이터 플랫폼과 연계 예정

Part 5

정리

1. 물성 예측 모델
2. 소재 스크리닝과 생성 모델
3. 문헌 데이터 활용
4. 자율실험실과 AI 에이전트
- 5. 정리**

오늘 내용 요약

문제	주요 방법	대표 논문	한계
물성 예측	GNN, 범용 포텐셜, LLM	ALIGNN, CHGNet, MatterChat	외삽, 학습 데이터 범위
스크리닝	ML 선별 + DFT + 능동학습	GNoME	합성 가능성
역설계	조건부 확산 모델	MatterGen	실험 검증
문헌 데이터	임베딩, LLM 기반 추출	Tshitoyan, ChatExtract	추출 오류, 출판 편향
자율실험	BO, 로봇, LLM 에이전트	A-Lab, Coscientist	자동 해석의 신뢰성

논문을 읽을 때 확인할 점

- 데이터: 출처(계산/실험/문헌)와 규모는? 성공한 데이터만 있는가?
- 검증 방식: 데이터를 어떻게 나눴는가? 누수 가능성은 없는가?
- 비교 기준: baseline이 공정한가? 같은 벤치마크, 같은 지표인가?
- 실험 검증: 실제로 합성·측정했는가? "발견"이라는 주장의 근거는 무엇인가?

참고문헌 (1/2)

- [1] E. O. Pyzer-Knapp et al., npj Comput. Mater. 11, 61 (2025). doi:10.1038/s41524-025-01538-0
- [2] A. Dunn et al., npj Comput. Mater. 6, 138 (2020). doi:10.1038/s41524-020-00406-3
- [3] K. Choudhary & B. DeCost, npj Comput. Mater. 7, 185 (2021). doi:10.1038/s41524-021-00650-1
- [4] C. Chen & S. P. Ong, Nat. Comput. Sci. 2, 718 (2022). doi:10.1038/s43588-022-00349-3
- [5] B. Deng et al., Nat. Mach. Intell. 5, 1031 (2023). doi:10.1038/s42256-023-00716-3
- [6] J. Riebesell et al., Nat. Mach. Intell. 7, 836 (2025). doi:10.1038/s42256-025-01055-1
- [7] K. M. Jablonka et al., Nat. Mach. Intell. 6, 161 (2024). doi:10.1038/s42256-023-00788-1
- [8] Y. Tang et al., Nat. Mach. Intell. 8, 588 (2026). doi:10.1038/s42256-026-01214-y
- [9] A. Merchant et al., Nature 624, 80 (2023). doi:10.1038/s41586-023-06735-9
- [10] A. K. Cheetham & R. Seshadri, Chem. Mater. 36, 3490 (2024). doi:10.1021/acs.chemmater.4c00643
- [11] C. Zeni et al., Nature 639, 624 (2025). doi:10.1038/s41586-025-08628-5
- [12] D. Gao et al., Nature 653, 707 (2026). doi:10.1038/s41586-026-10482-y

참고문헌 (2/2)

- [13] J. Wu et al., Science 386, 1256 (2024). doi:10.1126/science.ads0901
- [14] P. Raccuglia et al., Nature 533, 73 (2016). doi:10.1038/nature17439
- [15] V. Tshitoyan et al., Nature 571, 95 (2019). doi:10.1038/s41586-019-1335-8
- [16] O. Kononova et al., Sci. Data 6, 203 (2019). doi:10.1038/s41597-019-0224-1
- [17] J. Dagdelen et al., Nat. Commun. 15, 1418 (2024). doi:10.1038/s41467-024-45563-x
- [18] M. P. Polak & D. Morgan, Nat. Commun. 15, 1569 (2024). doi:10.1038/s41467-024-45914-8
- [19] T. J. Jacobsson et al., Nat. Energy 7, 107 (2022). doi:10.1038/s41560-021-00941-3
- [20] N. J. Szymanski et al., Nature 624, 86 (2023). doi:10.1038/s41586-023-06734-w
- [21] J. Leeman et al., PRX Energy 3, 011002 (2024). doi:10.1103/PRXEnergy.3.011002
- [22] D. A. Boiko et al., Nature 624, 570 (2023). doi:10.1038/s41586-023-06792-0
- [23] A. M. Bran et al., Nat. Mach. Intell. 6, 525 (2024). doi:10.1038/s42256-024-00832-8
- [24] T. Dai et al., Nature 635, 890 (2024). doi:10.1038/s41586-024-08173-7