UST 소재정보학 (Materials Informatics)

LLM 기반 소재 데이터 마이닝

Junhee Woo
한국화학연구원 디지털화학연구센터
jh1503@krict.re.kr

Who am I?

유/무기 소재
(MS, PhD)

Prof. Steve Park
Prof. Jihan Kim

고효율 공정 개발
(MS, PhD)

Prof. Steve Park
Prof. Gerbrand Ceder

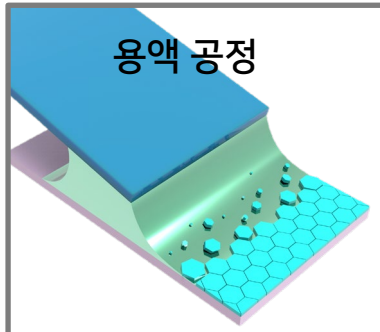
소재 AI 개발
(PhD)

Prof. Jihan Kim
Prof. Dong-Hwa Seo

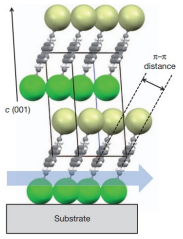
자율 실험 구축
(PhD, Postdoc)

소재 합성 & 분석

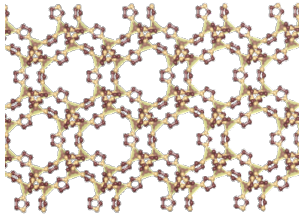
용액 공정



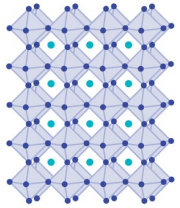
유기 반도체



MOF

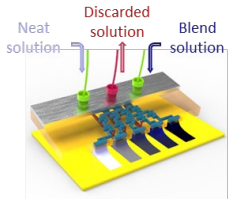


페로브스카이트

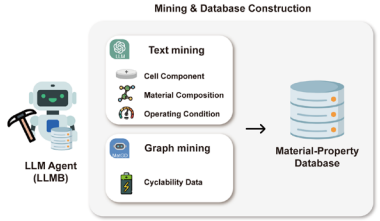


화학 소재 실험 데이터 수집

고효율 공정 개발

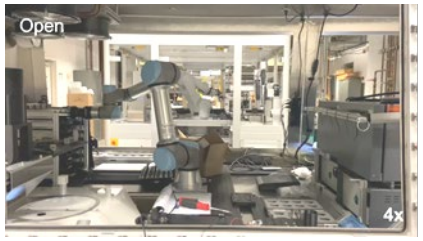


AI Agent 개발



AI optimization & Autonomy

비개방 자율 고상 합성

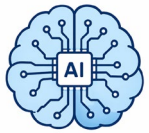


비평형 자율 고속 합성



KRICT 화학플랫폼 연구본부





전략연구사업

촉매 자율 실험실 구축 개발

KRICT
한국화학연구원
Korea Research Institute of Chemical Technology

연구 개발 방법론

Experimental

- ✓ 높은 정확도 데이터
- ✓ 시행 착오
- ✓ 시간, 자원 소모

Simulation

- ✓ 데이터 생성이 쉬움
- ✓ *In-situ* 와 다른 환경
- ✓ 복잡한 소자 환경 어려움

Data-driven Science



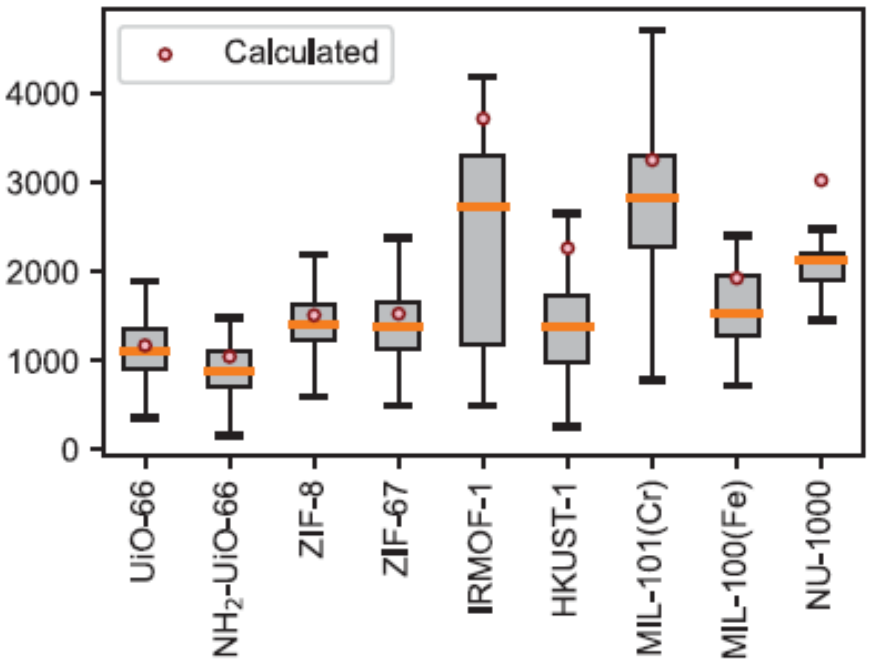
Database

- 실험적으로 검증된 데이터
- 논문 문헌으로부터 data mining
- 많은 수의 논문들 존재

소재 개발 연구를 위한 새로운 방법론 제안

계산값과 실험값의 차이

MOF 표면적 데이터



평균값

계산값

계산값: 하나

구조 1개 → 표면적 1개

문헌값: 분포

합성·활성화·측정 조건에 따라 수백 m^2/g 차이

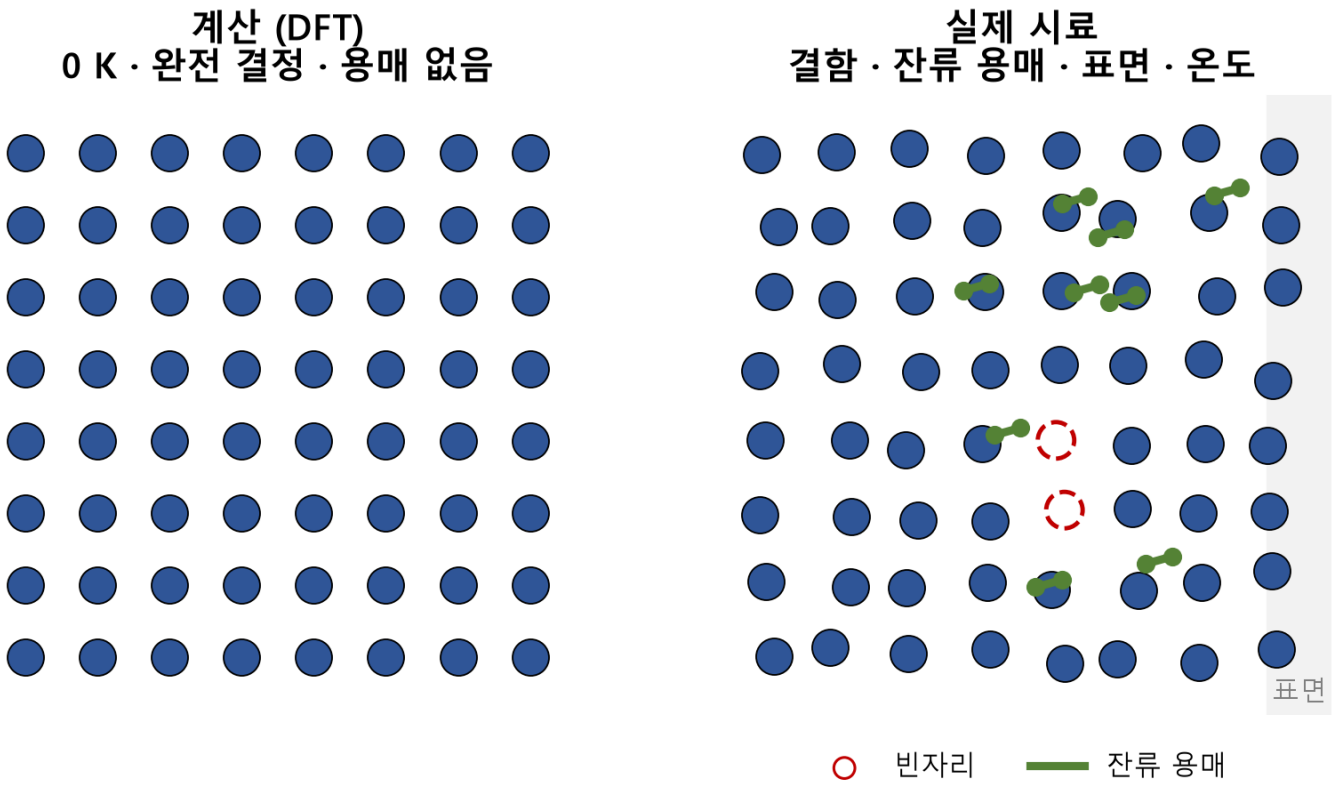
계산값 ≠ 문헌값 평균

틀린 값이 아니라 묻는 대상이 다름

문헌 데이터는 값이 아니라 **조건부 분포**

Kang et al., J. Am. Chem. Soc. 147, 3943 (2025)

계산 기반 예측의 성공과 한계



풍부한 계산 데이터

AFLOW 350만+, OQMD 100만+, GNoME 220만 구조 예측

계산은 ideal한 값

0 K, zero defect, 용매 없음, 등

실제 샘플

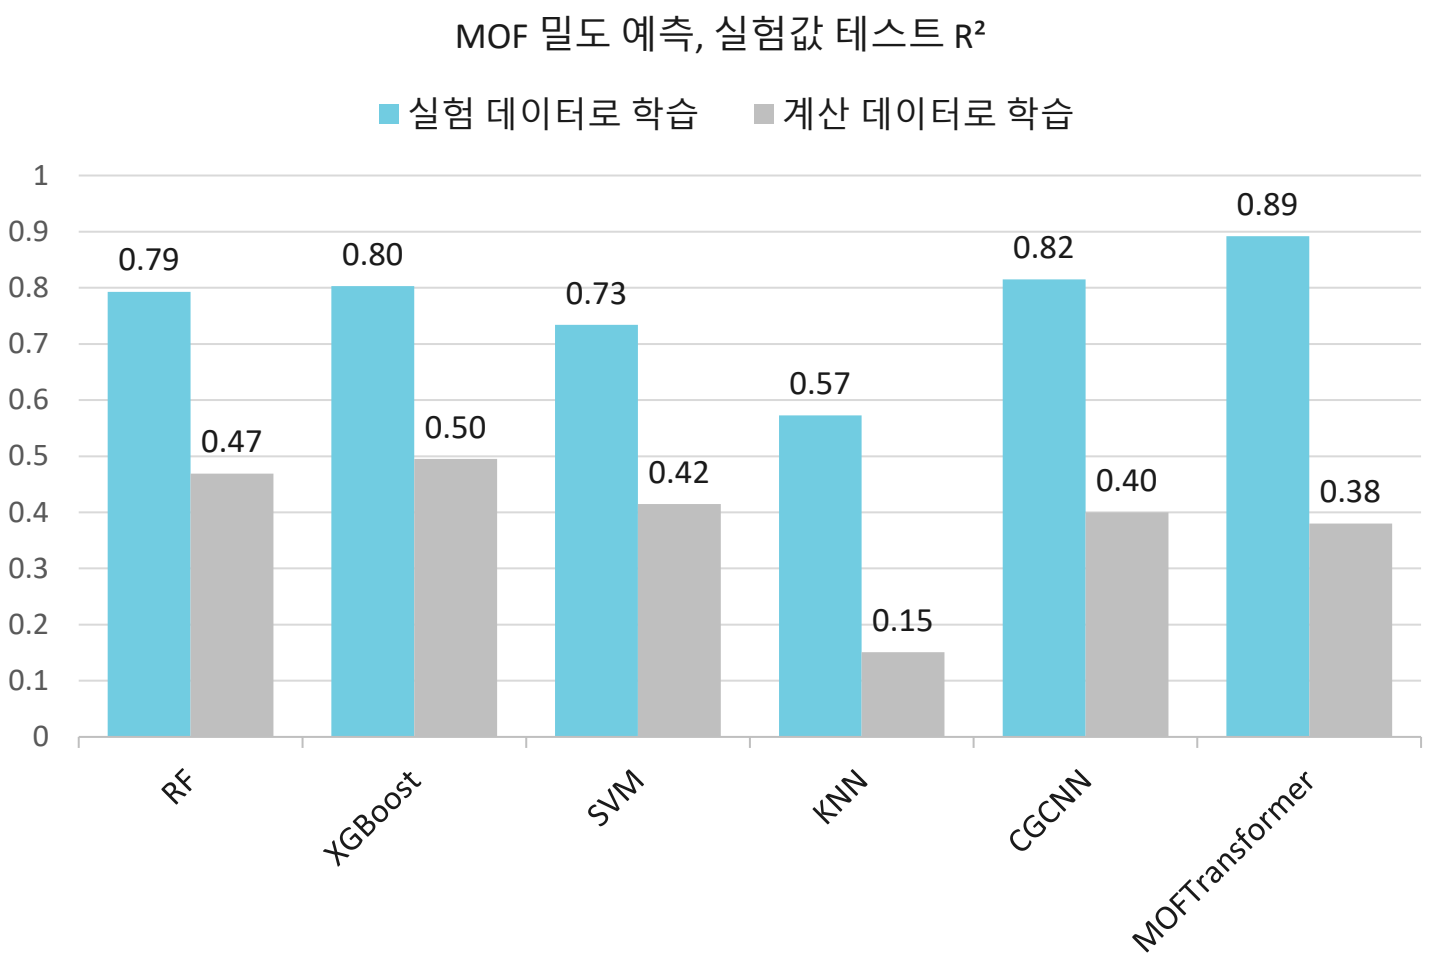
결함, 잔류 용매, 실험 조건, 등 모두 다름

합성 가능성은 계산만으로 판단 어려움

실험을 예측하려면 실험 데이터가 필요

Merchant et al., Nature 624, 80 (2023)

실제를 예측하기 위해 필요한 데이터



XGBoost R^2: 0.80 vs 0.50

실험 데이터로 학습한 모델이 실험값 예측에 우수

모든 모델에서 같은 경향

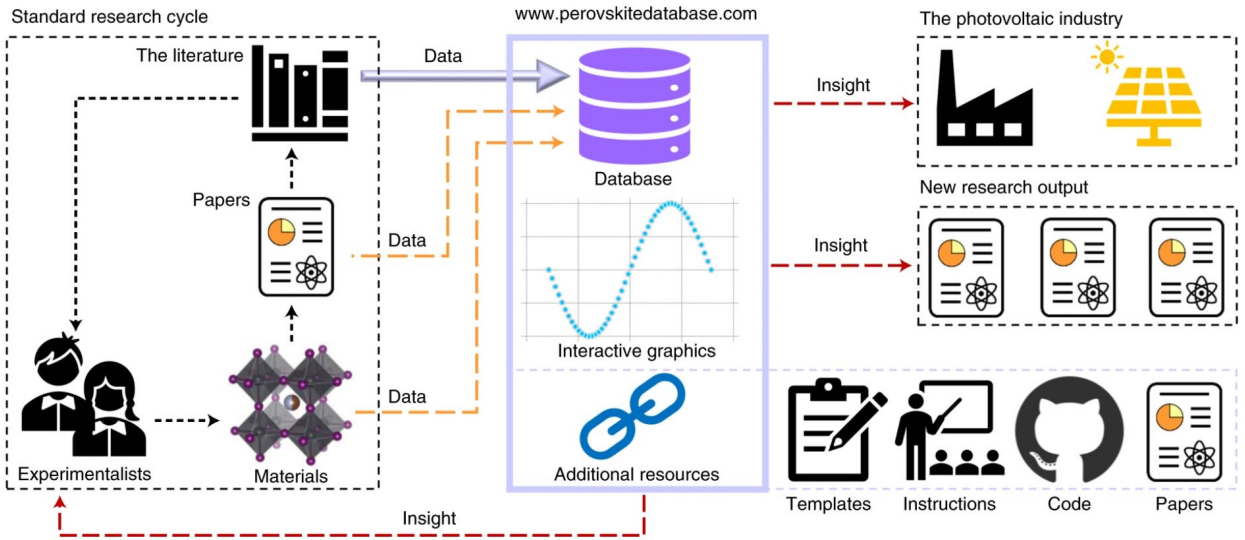
MOFTransformer: 0.89 vs 0.38

실험 데이터는 어디에?

실험 데이터 30,892점 → 논문에서 추출

Kang et al., J. Am. Chem. Soc. 147, 3943 (2025), Table 2

Part 1: LLM 기반 문헌 데이터 활용



구조 DB는 큼

ICSD 약 33.5만, CSD 약 143만 구조

물성·공정·소자 데이터는 논문 속

본문, 표, 그림, SI에 형식 없이 분산

수작업 수집의 한계

Perovskite DB: 약 95명, 15,000여 편
→ 소자 42,400개, 2021년 이후 갱신 중단

자연어는 사람용 → 기계가 읽으려면 **구조화** 필요

Jacobsson et al., Nat. Energy 7, 107 (2022)

기존 문헌 마이닝 연구의 흐름



- 규칙 기반: 낮은 정확도 (배터리 DB 재현율 59%) / 학습 기반: 높은 라벨링 비용
- 전구체 F1 0.99 / 혼합 조건 F1 0.65 → 모든 항목 기중 정확도 51% (조건 정보의 구조화 어려움)

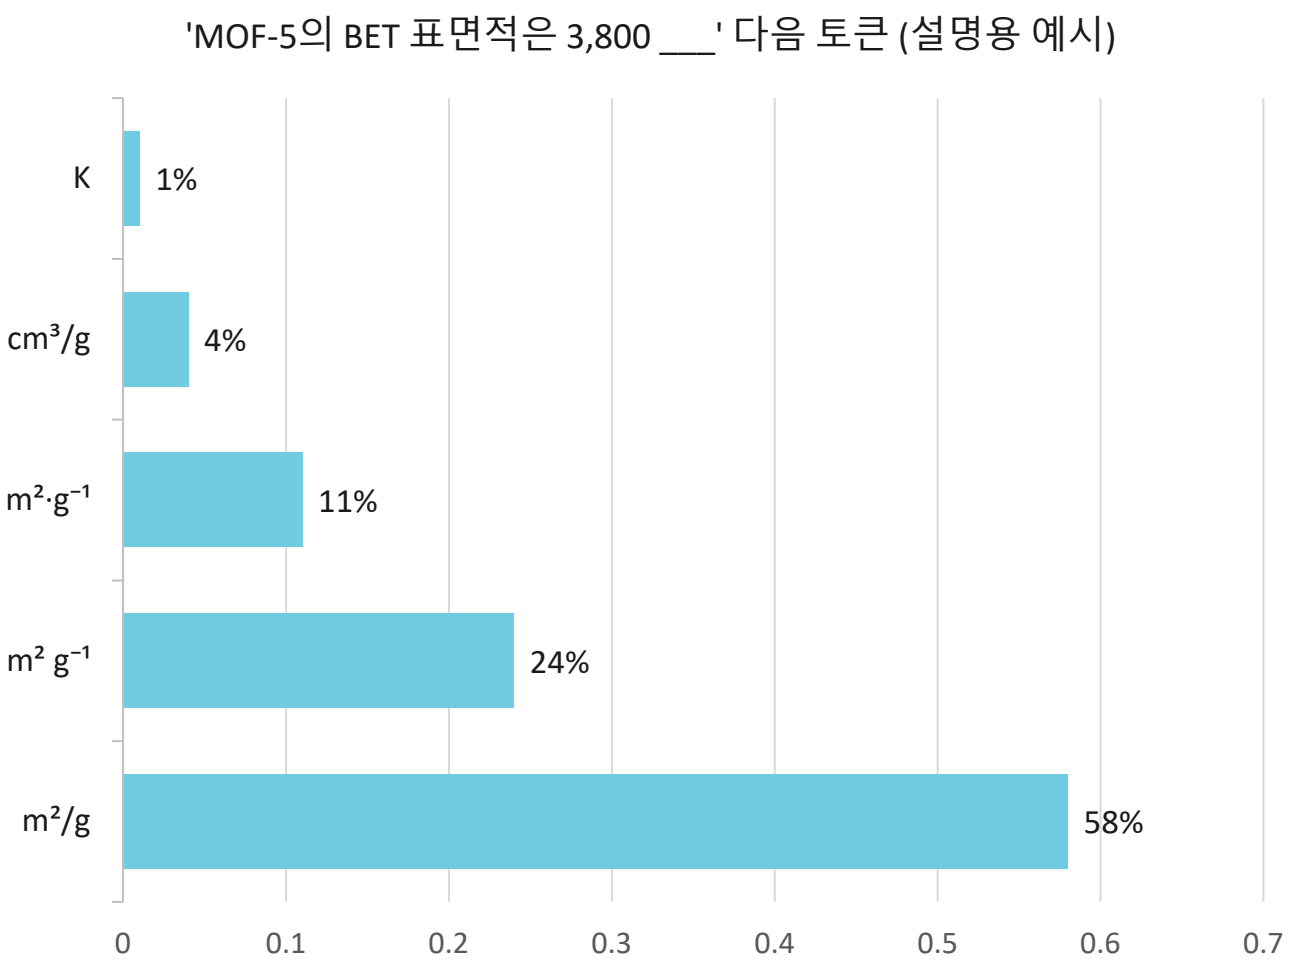
Swain & Cole 2016 · Kononova et al. 2019 · Tshitoyan et al. 2019 · Huang & Cole 2020 · Trewartha et al. 2022

규칙 기반, BERT, LLM의 비교

	규칙 기반	BERT (인코더)	LLM (생성형)
사람이 주는 것	문법, 정규식	라벨 수백–수천 건	지시문, 스키마, 예시 몇 개
출력	패턴에 맞는 문자열	단어마다 태그 (span)	구조화 레코드 (JSON)
관계와 맥락	규칙으로 직접 작성	별도 모델 필요	한 번에
새 물성	규칙 새로 작성	다시 주석, 다시 학습	지시문 수정
실패 양상	놓침 (재현율 ↓)	경계·관계 오류	환각, 결과가 매번 다름

LLM: 라벨 대신 지시문 → 대신 환각 위험

LLM: 다음 토큰을 예측하는 모델



사전학습

웹·책·논문·코드 수조 토큰 → 다음 토큰 예측으로 언어·지식 학습

지시 학습

질문–답 예시, 사람 선호로 '시키는 일'을 하도록 조정

사용

재학습 없이 지시문 + 예시 몇 개로 새 과제 수행

가장 그럴듯한 답 → 환각의 원인

추출 스키마

```
{ "material": <이름>,
  "property": <물성>,
  "value": <숫자>,
  "unit": <단위>,
  "method": <측정법>,
  "this_work": <참/거짓>,
  "evidence": <근거 문장> }
```

UiO-66 was activated at 150 °C. The N_2 isotherm at 77 K gave a BET surface area of 1,250 $m^2 g^{-1}$, higher than the value reported previously (1,100 $m^2 g^{-1}$) [23].

LLM →

```
{ "material": "UiO-66",
  "property": "BET 표면적",
  "value": 1250,
  "unit": "m2/g",
  "method": "N2, 77 K",
  "this_work": true,
  "evidence": "The N2 …" }
```

스키마 | **원문 문단** | **구조화 출력**

- LLM: 원문 → 스키마에 맞는 레코드 (인용된 이전 값 1,100은 제외)
- 핵심은 여전히 스키마 설계, 검증

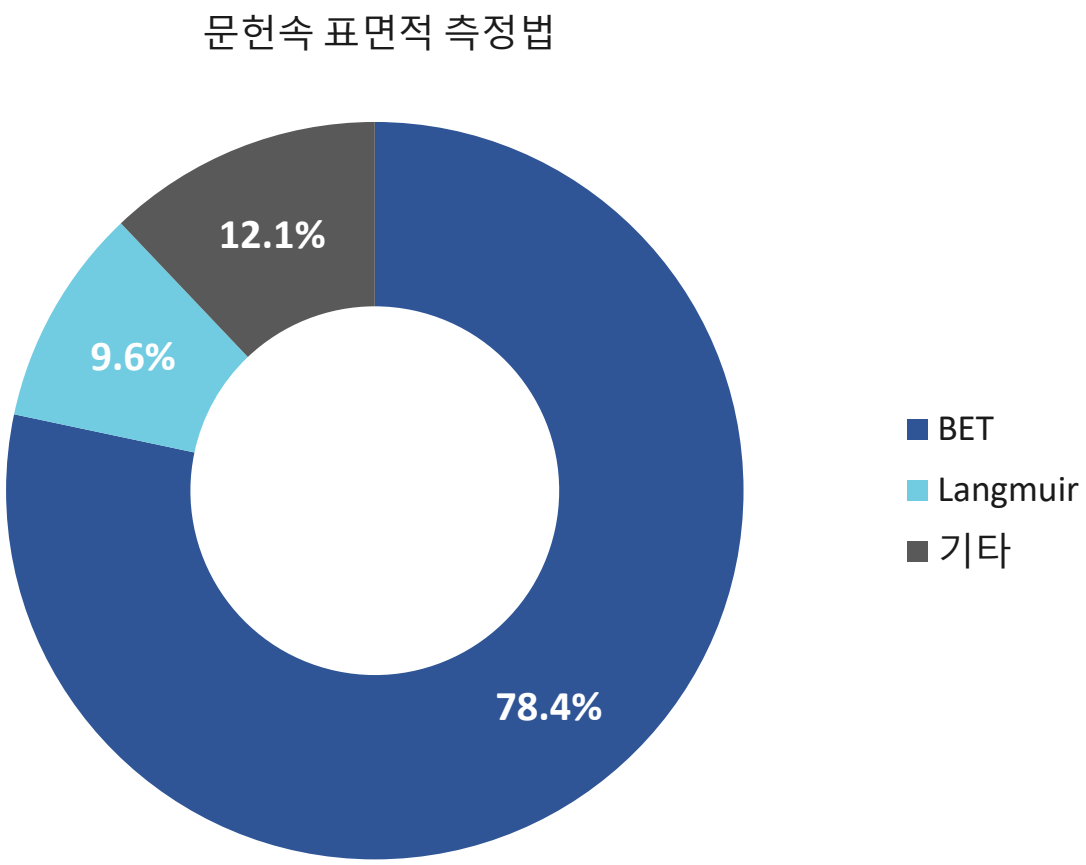
Dagdelen et al., Nat. Commun. 15, 1418 (2024)

논문에서 무엇을 꺼내야 하나

정보	예	왜 필요한가
물질 식별	이름, 화학식, CSD refcode, SMILES	같은 물질 묶기, 다른 DB와 연결
합성 · 공정	전구체, 용매, 온도, 시간, 활성화	재현, 합성 추천, 시료 차이의 원인
물성값 + 단위	표면적 1,250 m^2/g	ML의 학습 목표값
측정법 · 조건	BET / Langmuir, 77 K, C-rate	방법을 알아야 같은 기준끼리 비교 가능
소자 · 성능	셀 구성, 사이클별 용량	응용 성능은 계산으로 얻기 어려움
출처	DOI, 근거 문장	검증, 재현, 오류 추적

숫자 + 맥락 = 데이터

데이터 맥락의 중요성



표면적: BET 78.4%, Langmuir 9.6%

측정법 구분 없이 합치면 다른 물리량이 섞임

소재의 성능 값도 측정조건에 따라 다름

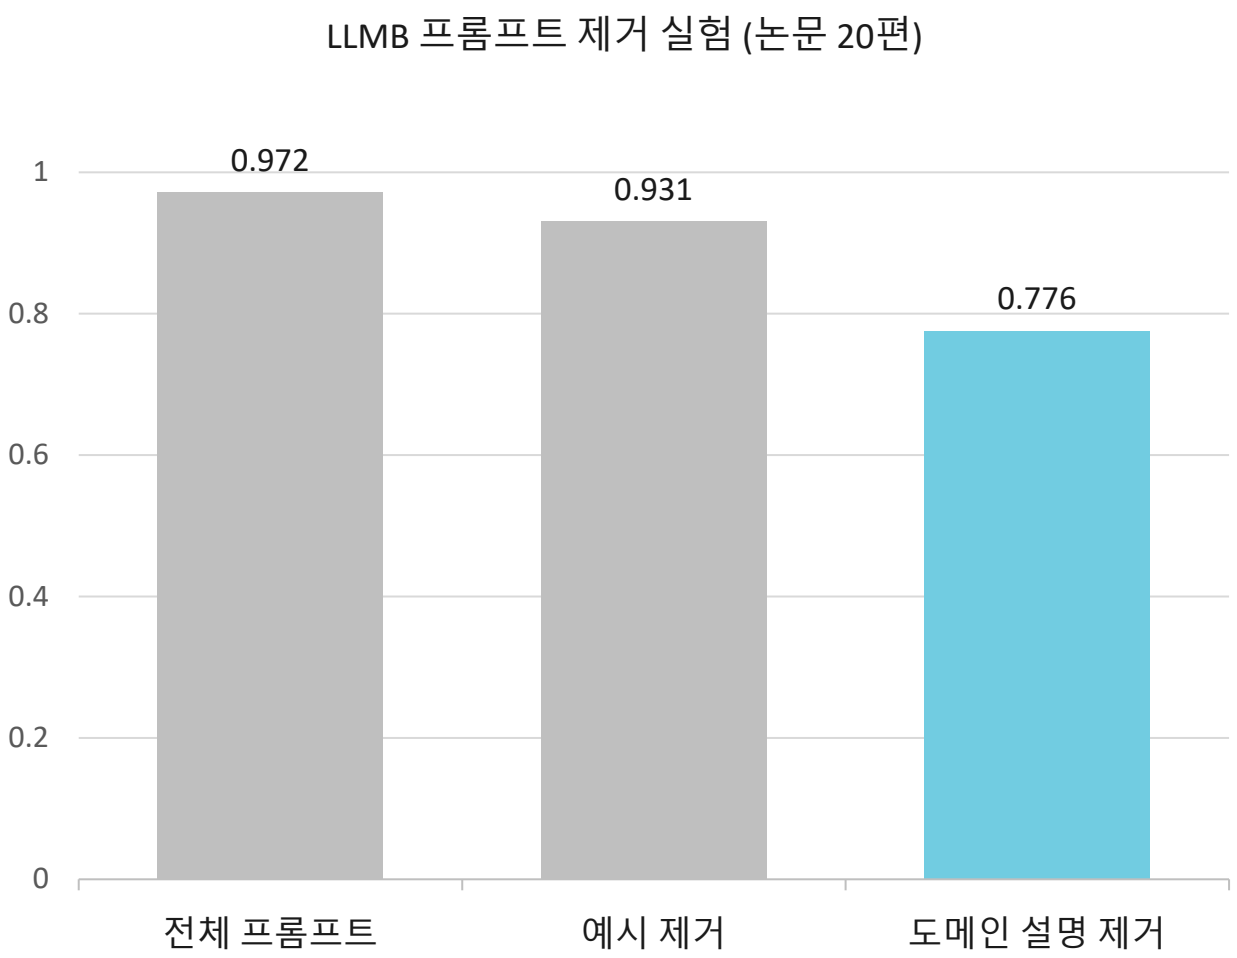
(배터리)C-rate, 로딩, 전압 범위, 온도, 사전 사이클, 등

같은 물질, 여러 값

평균? 중앙값? 조건별 분리? → 이 선택 = ML 문제 정의

Kang et al., J. Am. Chem. Soc. 147, 3943 (2025)

도메인, 단계, 검증



도메인 지식의 중요성

도메인 설명 제거 시 F1 0.972 → 0.776

단계 분리 (L2M3)

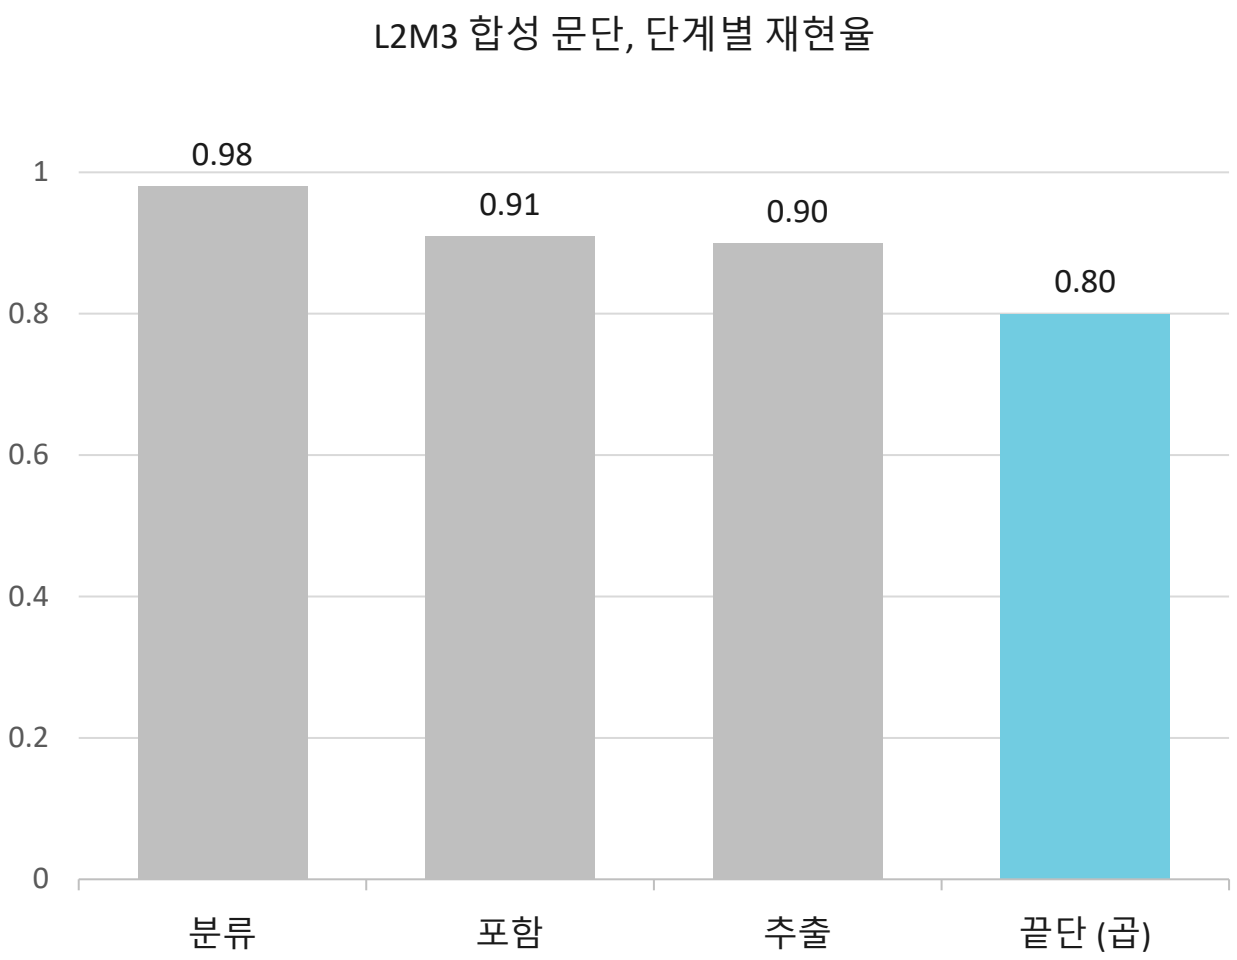
분류 → 포함 → 추출 26.91달러
GPT-4 한 번에 703.58달러

검증 질문

ChatExtract: 정밀도 42.7% → 90.8%

Lee, Woo et al., ACS Cent. Sci. 12, 484 (2026) · Kang et al. 2025 · Polak & Morgan, Nat. Commun. 15, 1569 (2024)

마이닝 데이터 검증



단계적 방법의 위험성

0.98 × 0.91 × 0.90 ≈ 0.80 → 오차 증가
단계별 + 끝단 평가 모두 필요

Kang et al. 2025 · Dagdelen et al. 2024 · Foppiano et al., STAM Methods 4, 2356506 (2024)

Challenge of the LLM

위험	실제 사례	대응
환각	존재하지 않는 'MOF-99999'의 합성 조건을 지어냄	'모르면 모른다' 허용, 근거 문장 인용
단위 실수	0.56 m²/g → 5.6 m²/kg (정답은 560)	원값과 단위만 뽑고 환산은 코드로
기억에 의존	표준 물성값을 외워서 답함	주어진 글에서만 읽게 함
비결정성	같은 입력 1,000번에 출력 80가지	원응답 저장, 다수결
모델 종료	GPT-4·3.5 계열 2026-10-23 종료	버전 기록, 오픈 가중치

LLM = 기억 장치 x, 읽기 장치 o

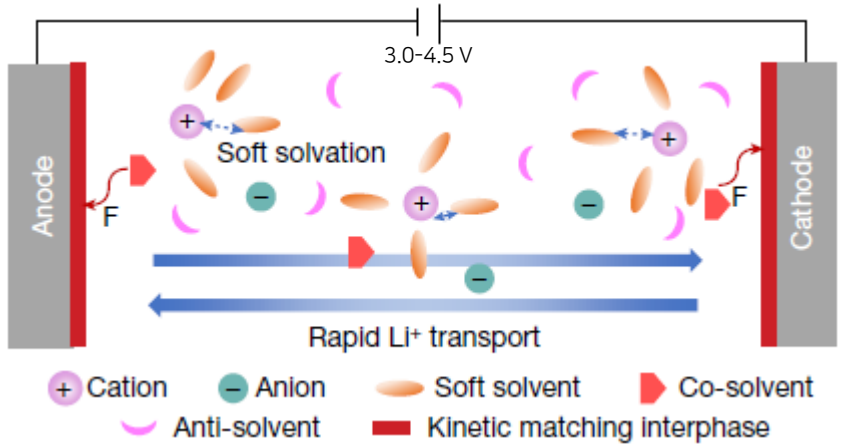
Zheng et al., JACS 145, 18048 (2023) · arXiv:2604.22938 · Thinking Machines (2025)

Case Study

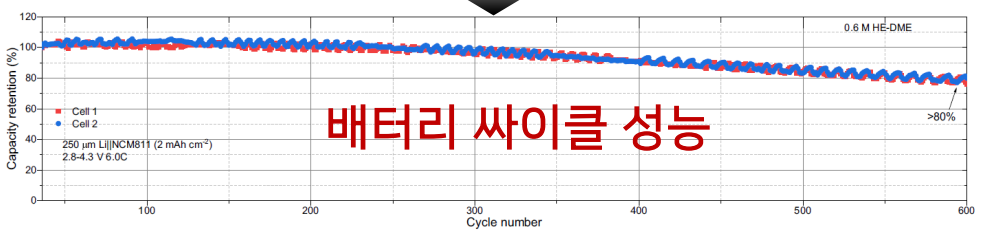
LLMB: 리튬금속전지 연구를 위한 LLM 에이전트

Data-driven Science의 필요성

Lithium Metal battery



- **양극**: $Li(Ni_xCo_yMn_{1-x-y})O_2$, $LiFePO_4$, Sulfur composite)
- **분리막**: 양극과 음극 사이의 물리적 분리
- **전해질**: Li^+ 이온 이동 매개체
- **집전체**: 활물질에 전자를 전달하는 매개체
- **음극**: Li metal (Li^+ ion storage)



Experimental

- ✓ 높은 정확도 데이터
- ✓ 시행 착오
- ✓ 시간, 자원 소모

Simulation

- ✓ 데이터 생성이 쉬움
- ✓ *In-situ* 와 다른 환경
- ✓ 복잡한 소자 환경 어려움

Data-driven Science



Database

- 실험적으로 검증된 배터리 데이터
- 논문 문헌으로부터 소재, 성능 data mining
- 많은 수의 논문들 존재
  (over 7000 LMB papers from Elsevier journals)

배터리 연구를 위한 새로운 방법론 제안

- 고에너지 용량의 차세대 배터리 소재 개발
- 리튬 금속의 높은 반응성으로 인한 소재 안정성 문제
- 소재-성능 관계에 대한 유효한 실험 데이터 필요

논문 예시

nature communications

Article

https://doi.org/10.1038/s41467-023-36075-1

High entropy liquid electrolytes for lithium batteries

Received: 19 August 2022

Accepted: 12 January 2023

Published online: 27 January 2023

Check for updates

Qidi Wang[1,8], Chenglong Zhao[1,8] ✉, Jianlin Wang[2,8], Zhenpeng Yao[3,4,8], Shuwei Wang[5], Sai Govind Hari Kumar[6], Swapna Ganapathy[1], Stephen Eustace[7], Xuedong Bai[2], Baohua Li[5] & Marnix Wagemaker[1] ✉

High-entropy alloys/compounds have large configurational entropy by introducing multiple components, showing improved functional properties that exceed those of conventional materials. However, how increasing entropy impacts the thermodynamic/kinetic properties in liquids that are ambiguous. Here we show this strategy in liquid electrolytes for rechargeable lithium batteries, demonstrating the substantial impact of raising the entropy of electrolytes by introducing multiple salts. Unlike all liquid electrolytes so far reported, the participation of several anionic groups in this electrolyte induces a larger diversity in solvation structures, unexpectedly decreasing solvation strengths between lithium ions and solvents/anions, facilitating lithium-ion diffusivity and the formation of stable interphase passivation layers. In comparison to the single-salt electrolytes, a low-concentration dimethyl ether electrolyte with four salts shows an enhanced cycling stability and rate capability. These findings, rationalized by the fundamental relationship between entropy-dominated solvation structures and ion transport, bring forward high-entropy electrolytes as a composition-rich and unexplored space for lithium batteries and beyond.

- Battery cycle life ← **Figure**
- Battery cell information ← **Caption, Result**
- Material information ← **Experimental**

논문 예시

electrolyte, the inorganic rich SEI/CEI and improved lithium-ion kinetics are attributed to the increasing entropy of mixing, resulting in denser lithium metal growth, despite the low concentration of HE electrolyte. Based on the above results, the characteristics of conventional dilute electrolytes, high salt concentration electrolytes and HE electrolytes are compared in Fig. 5i. From this comparison, the HE demonstrates promising assets, especially realizing that it enables improved stability against the anode/cathode in low salt concentration liquid electrolytes, which typically can be achieved in highly concentrated electrolytes (Supplementary Fig. 83).

In summary, we present liquid electrolytes with multiple salts and investigated the role and impact of entropy in this class of materials. Via introducing multiple salts (e.g., LiFSI, LiTFSI, LiDFOB, and $LiNO_3$) in an ether solvent, a HE electrolyte has been prepared for the proof of concept, which exhibits a higher reversibility for lithium metal plating/stripping and a higher oxidation stability for Ni-rich cathode charging to a high cut-off voltage and results in improved rate performance. Despite the low salt concentration (0.6 M) and the poor oxidation stability of DME, the high entropy endows the solution with the demonstrated promising electrolyte properties. The results show that more salt anions participate in the solvation structures of the low-concentration HE electrolyte, resulting in a thinner and inorganic-rich SEI compared to the single salt electrolyte. The improved interphase properties enhance anodic and cathodic electrochemical stability (Supplementary Fig. 84), and results in more compact lithium metal plating and higher oxidative stability of ether-based solvents for 4 V-class lithium batteries. This rationalises the improved reversibility of the charge/discharge cycles and improved rate performance that exceeds these of conventional electrolytes. Moreover, the observed weaker solvation strengths between lithium ions and the solvents/anions, as compared to the commonly single-salt low- and high-concentration electrolytes, is held responsible for the enhanced charge transfer and the improved electrolyte conductivity. This is the consequence of the increased entropy of mixing leading to more diverse and more facile solvation rearrangements in the HE electrolyte (Supplementary Figs. 82 and 83).

The compositional landscape of HE materials is huge, as the chemistry and relative amounts of both solvents and salts can be varied. The present investigation suggests that raising the entropy by introducing multiple salts can be used to improve its functional properties through the solvation structure, where the choice of specific salts and solvents should be guided by their interactions with the specific anode and cathode chemistry. This is further supported by preparing a five-component salt HE electrolyte supporting even longer stable cycling (Supplementary Figs. 85–87 and Supplementary Note 10). This exploration motivates more fundamental and systematic research, which is of general scientific importance and will guide the development of better electrolyte systems and beyond.

Methods

Materials and synthesis

Lithium metal foils (thickness of 250 μm), Cu foils and Al foils were purchased from MTI Corporation, and lithium metal foils (50 μm) were purchased from China Energy Lithium Co., Ltd. All lithium metal foils were washed three times with dimethoxyethane (DME) solvent before use. Cu foils were immersed in diluted acetic acid for several minutes, subsequently washed by deionized water and acetone three times, separately, then they were quickly dried in the vacuum oven of glove box at room temperature. DME solvent was purchased from Sigma-Aldrich, which was dehydrated with a 4 Å molecular sieve (Sigma-Aldrich) to eliminate the possible trace water. Lithium bis(-fluorosulfonyl)imide (LiFSI), lithium bis(trifluoromethanesulfonyl) imide (LiTFSI), Lithium Difluoro(oxalato)borate (LiDFOB) were obtained from Sigma-Aldrich, and Lithium bis(pentafluoroethanesulfonyl)imide (LiBETI) were obtained from 3 M company, which were dried under vacuum condition at 80 °C for 24 h after purchased. Lithium nitrate ($LiNO_3$, > 99.9%) was purchased from Shenzhen Capchem Technology Co., Ltd and used as-received. All the electrolytes were prepared by dissolving the specific amount of different lithium salts in DME solvent in an Ar-filled glove box (H_2O < 0.1 ppm, O_2 < 0.1 ppm). 0.6 mol L^{-1} (M) LiFSI-DME, 0.6 M LiTFSI-DME, 0.6 M LiDFOB-DME and 0.36 M $LiNO_3$-DME electrolytes denote that the corresponding concentration of different salts are dissolved in DME, where 0.6 M $LiNO_3$-DME electrolyte can't be prepared because of the relatively low salt solubility. HE-DME electrolyte was prepared by dissolving 0.15 M LiFSI, 0.15 M LiTFSI, 0.15 M LiDFOB and 0.15 M $LiNO_3$ into DME solvent with the total concentration of lithium ion to be 0.6 M. 5-component 0.6 M HE-DME electrolyte was prepared by dissolving 0.15 M LiFSI, 0.10 M LiTFSI, 0.10 M LiBFTI, 0.10 M LiDFOB and 0.15 M $LiNO_3$ into DME solvent with the total concentration of lithium to be 0.6 M.

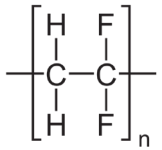
$LiFePO_4$ was obtained from Leneng Technology for which the cathodes were prepared by mixing $LiFePO_4$ material, poly(vinylidene difluoride) (PVDF, MTI) binder and Super P (Alfa Aesar) conductive carbon in a weight ratio of 92:4:4. The resulting slurry was cast on the Al foil then dried at 60 °C for 6 h, followed by drying overnight at 120 °C in a vacuum oven. $Li_4Ti_5O_{12}$ anode was purchased from MTI Corporation as received. $LiNi_{0.8}Co_{0.1}Mn_{0.1}O_2$ (NCM811) was synthesized using coprecipitation method. The certain amount of alkaline aqueous solution (NH_4OH and NaOH) was poured into deionized water (1.5 L) to form the base solution in a tank reactor under continuous stirring. Then, a 2 M solution of $NiSO_4 \cdot 6H_2O$, $CoSO_4 \cdot 7H_2O$, and $MnSO_4 \cdot H_2O$ with a molar ratio of 8:1:1 and an aqueous solution of 5 M NH_4OH and 10 M NaOH were added into the base solution in the tank reactor with a steady rate of 8 mL min^{-1}. The coprecipitation temperature was controlled at 50 °C, and pH value was maintained at around 11 by NH_4OH with stirring speed of 500 rpm under nitrogen atmosphere. The coprecipitated $Ni_{0.8}Co_{0.1}Mn_{0.1}(OH)_2$ precursor was prepared, which was subsequently washed by deionized water and ethanol for four times and dried in a vacuum at 120 °C for 24 h. The apparent and tap density of $Ni_{0.8}Co_{0.1}Mn_{0.1}(OH)_2$ precursor are 1.88 g cm^{-3} and 2.06 g cm^{-3}, respectively. For preparation of NCM 811 materials, the as-obtained precursor was mixed with $LiOH \cdot H_2O$ at a molar ratio of 1:1.03; then firstly heated at 500 °C for 5 h and subsequently calcined at 780 °C for 12 h in oxygen atmosphere. After cooling naturally, the obtained material was directly put into an Ar-filled glovebox to prevent any moisture exposition. The NCM811 electrodes were prepared by mixing active material, Super P and PVDF binder in the mass ratio of 90:5:5 in N-methyl-2-pyrrolidone (NMP) solvent and cast on Al foil and then dried at 60 °C for 6 h, followed by drying in a vacuum oven at 120 °C overnight. X-ray diffraction pattern demonstrates the pure phase of this prepared NCM811 material.

Electrochemical measurements

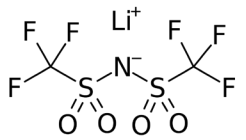
Electrochemical cycling tests of all batteries were based on CR2032 coin cells assembled in an Ar-filled glove box (H_2O < 0.1 ppm, O_2 < 0.1 ppm) with Celgard 2500 separator and tested at room temperature, unless stated otherwise. 70 μL electrolytes were injected into each coin cell for comparison. All coin cells were tested using multi-channel battery testing systems (Land CT2001A or Lanhe G340A) at room temperature. Symmetric Li||Li cells were assembled to study the cycling stability under different current densities with various electrolytes. 15.6 mm diameter lithium metal foils with 250 μm thickness were used as both the working and counter electrodes. For Li||Cu cells, 14 mm diameter lithium metal foils were used as the reference, while 16 mm Cu foils was used as a working electrode with the effective area for lithium deposition of 1.54 cm^2. During cycles, capacity of 1 mAh cm^{-2} lithium was deposited on Cu foils at a current density of 0.5 mA cm^{-2} and then stripped to a cut-off voltage of 1.0 V vs Li/Li^+.

: Cell type
: Cathode
: Anode
: Separator
: Electrolyte
: Current collector
: C-rate

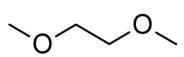
Parts	Type	Descriptor
Cell type	coin cell / pouch cell	0, 1
Cathode	NCM: ($LiNi_xCo_yMn_{1-x-y}O_2$)	분자식, loading 양
	LFP: $LiFePO_4$	분자식, loading 양
	Sulfur: Sulfur : Host material	분자식, loading 양
	binder: polymer	SMILES
	conductive additive: Carbon black, CNT, Super P,..	SMILES
	active material : conductive additive : binder 무게비율	number
Anode	Li metal: 두께	number
Separator	celgard (polypropylene) + α	SMILES
Electrolyte	electrolyte: $LiPF_6$, LiTFSI, LiFSI,..	SMILES, 농도
	solvent: DMC, DME, EC, G2, Toluene,..	SMILES, 비율
	E/A ratio: electrolyte 양 (μl/mg)	number
Current collector	Cu, Al, carbon coated Al,	
구동 조건	C-rate of cycle-capacity Current density (mA/cm^2) Temperature	number



PVDF



LiTFSI



DME

.....

논문 예시

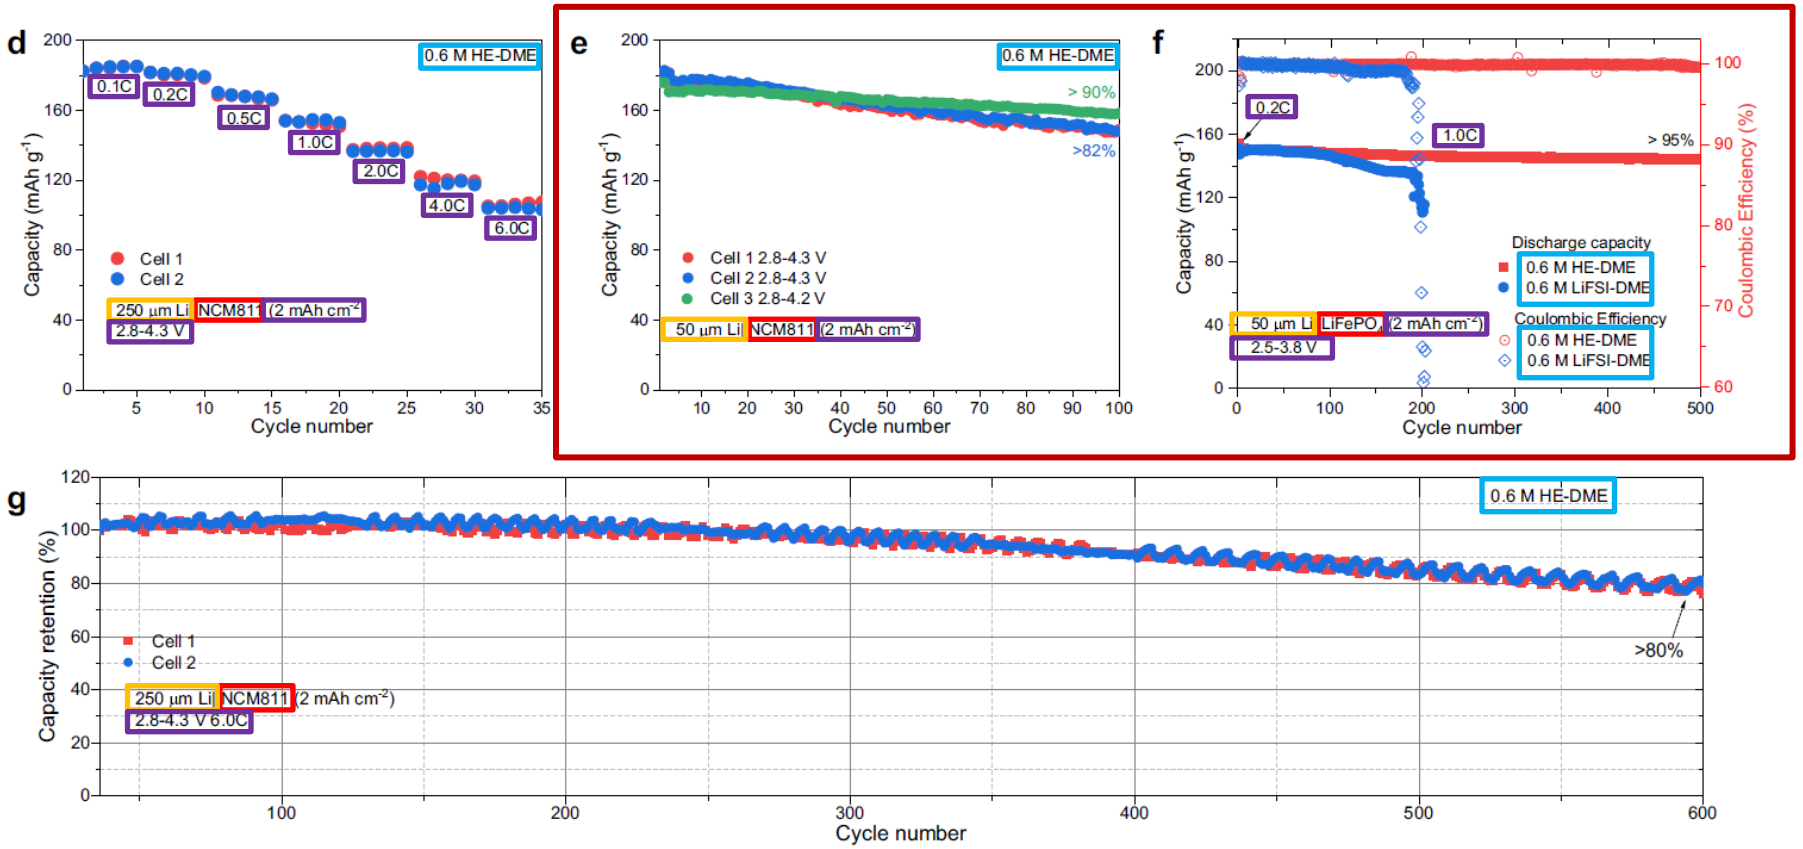


Fig. 2 | Electrochemical performance. a, **b** Galvanostatic charge/discharge curves of $LiNi_{0.8}Co_{0.1}Mn_{0.1}O_2$(NCM811) cells in **a** 0.6 M LiFSI-DME, **b** 0.6 M HE-DME electrolytes within the voltage range of 2.8–4.3 V at a rate of 0.1 C (1 C = 180 mA g^{-1}). Cells were tested with a capacity of 2 mAh cm^{-2} for NCM811 and 50 μm lithium metal foils, resulting in a negative/positive capacity ratio (N/P) of 5. **c** Galvanostatic charge/discharge curves of NCM811 cells in the 0.6 M HE-DME electrolyte at different rates. **d** Electrochemical rate capability of NCM811 in the 0.6 M HE-DME electrolyte. **e** Cycling performance of NCM811 in the 0.6 M HE-DME electrolyte cycled at a 0.1 C rate for three cycles before cycling at a 0.333 C rate at different voltage ranges. **f** Cycling performance of $LiFePO_4$ (LFP) cells cycled at a 0.2 C rate for three cycles before cycling at a 1.0 C rate. **g** Long-term cycling capacity retention of NCM811 cells in the 0.6 M HE-DME electrolyte cycled at a rate of 6.0 C.

기존 배터리 마이닝

BatteryBERT: A Pretrained Language Model for Battery Database Enhancement

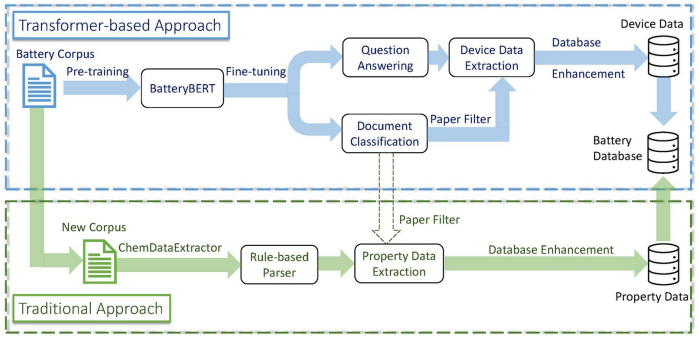


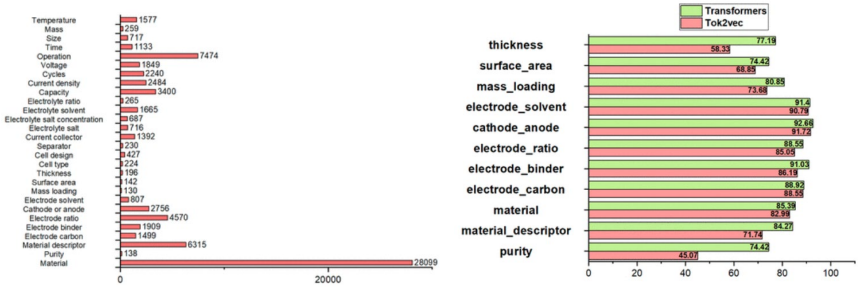
Table 10. Number of Data Records and Unique Data Records for Anode, Cathode, and Electrolyte Materials

types	no. of device records	no. of unique device records
anode	157885	6210
cathode	118310	6179
electrolyte	32769	1663
total	308964	14052

J. Chem. Inf. Model. 2022, 62, 24, 6365–6377

LIBAC: An Annotated Corpus for Automated Reading of the Lithium-Ion Battery Research Literature

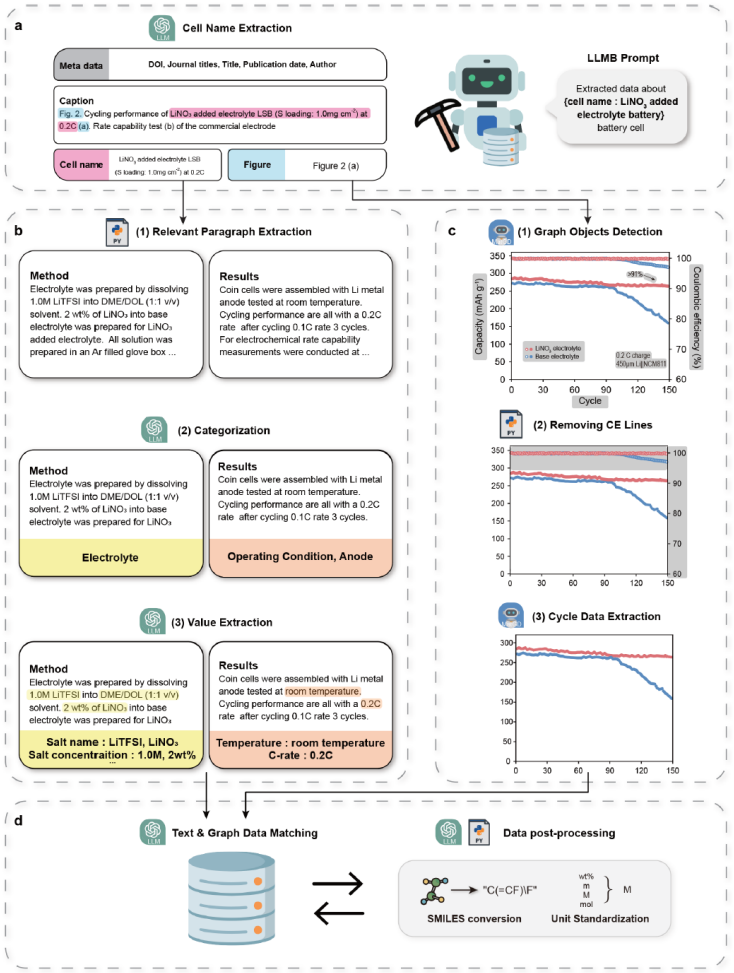
The composite positive electrodes consisted of $LiNi_{0.8}Co_{0.15}Al_{0.05}O_2$ as active material , conductive additives and polyvinylidene fluoride binder in the weight ratio 84:8:8 . Carbon black (Super P) and graphite (SFG6) ... N-methylpyrrolidone (NMP) was used for preparing the binder solutions ... The resulting slurry was coated onto aluminium foil (22 m thickness) using the doctor-blade technique and then dried at 80 °C to evaporate NMP . The film was after that dried overnight at 120 °C ... The electrodes containing graphite as the only conductive agent showed at C/5-rates a discharge capacity of only 100 $mAhg^{-1}$ ...



Chem. Mater. 2023, 35, 5, 1849–1857

- Conventional methods are inadequate for capturing the complex synthesis process of battery
- Data is extracted from the entire paper rather than from individual battery cells
- The absence of graph mining tools prevented the extraction of graph data of batteries

성능은 그림에, 재료는 본문에



본문

양극, 전해질, 음극, 분리막, 농도, C-rate, 온도

그림

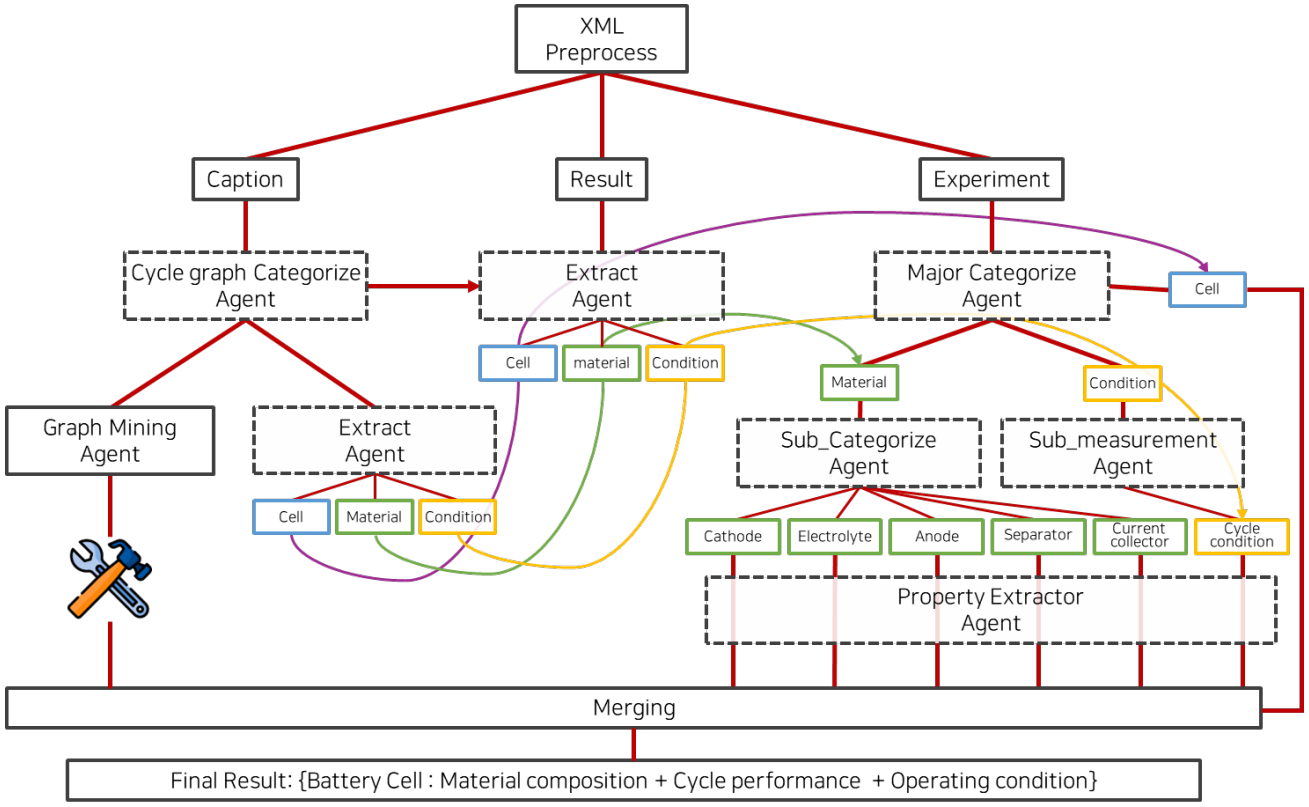
사이클별 용량 곡선 + 쿨롱효율이 한 그래프에

목표

배터리 셀 기준의 구성 소재, 배터리 성능, 측정 조건 정보 수집

Lee, Woo et al., ACS Cent. Sci. 12, 484 (2026)

LLMB 파이프라인



1. **셀 이름** 캡션에서 셀 이름과 그림 번호
2. **문단 선택** 관련 문단만 (파이썬)
3. **분류** 대분류 → 소분류
4. **값 추출** 범주별 프롬프트, 개체 29종
5. **그래프** MatGD로 선 분리, 쿨롱효율 제거
6. **매칭** 범례 ↔ 셀 이름 (LLM)
7. **후처리** SMILES 변환, 단위 표준화

Lee, Woo et al., ACS Cent. Sci. 12, 484 (2026)

Prompt Engineering

PROMPT_ELECTROLYTE = '''

System Prompt

Extract the relevant information about electrolyte {name_material} mentioned in the paragraph.
There are {name_cell} name of cells are exist.
Electrolyte is consisted of Li salts and solvents.

Format

There are guild lines for output Json format:
- You must write like

```
[
   {{
      "name_electrolyte" : {name_material[0]},
      "Li_salt" : {{ "material": [str, str,...],
      "concentration":[float, float,...],"unit": [str, str ...]}},
      "solvent" : {{ "material": [str, str,...],
      "solvent_volume_ratio":[float, float, ...], "unit": [str, str, ...]}},
      "EA_ratio" : float
   }},...
]
```

Rules

You must follow rules below:
- The "name_electrolyte" is one of the {name_material}, representing the name of the electrolyte.
  You are required to thoroughly investigate all the electrolyte present here without missing any.
- The electrolyte is one of the components that make up a battery cell.
- If there are 2 or more electrolyte combinations exist in paragraph, you must extract all electrolytes.
- If there are additive salt in paragraph, it is same as Li salt and you must include "Li_salt" once.
- "EA_ratio" is ratio of electrolyte(in mL) and active materials(in mg). In Lithium sulfur battery, it is same as ES ratio.
- If the "EA_ratio" value is mentioned multiple times, extract each with a different electrolyte.
- The "unit" of "solvent" is typically v, v% or wt%, each means volume, volume% and weight%.
- If you're uncertain, fill "null".

Examples

Begin!
name_electrolyte: ["DD of 1.0 M LiTFSI in DOL/DME (v:v = 1:1)", "DD-N of 1.0 M LiTFSI in DOL/DME (v:v = 1:1) 5wt% LiNO3"]
Paragraph: The electrolyte of DD was 1.0 M LiTFSI in DOL/DME (v:v = 1:1) and DD-N was DD with 5wt% LiNO3.
Json:

```
[
   {{
      "name_electrolyte" : "DD of 1.0 M LiTFSI in DOL/DME (v:v = 1:1)",
      "Li_salt":{{ "material": ["LiTFSI"], "concentration":[1.0],"unit": ["M"]}},
      "solvent":{{ "material": ["DOL", "DME"], "solvent_volume_ratio":[1,1], "unit": [v, v]}},
      "EA_ratio": null
   }},
   {{
      "name_electrolyte" : "DD-N of 1.0 M LiTFSI in DOL/DME (v:v = 1:1) with 5wt% LiNO3",
      "Li_salt":{{ "material": ["LiTFSI", "LiNO3"], "concentration":[1.0, 5],"unit": ["M", "wt%"]}},
      "solvent":{{ "material": ["DOL", "DME"], "solvent_volume_ratio":[1,1], "unit": [v, v]}},
      "EA_ratio": null
   }}
]
```

Example of extract result

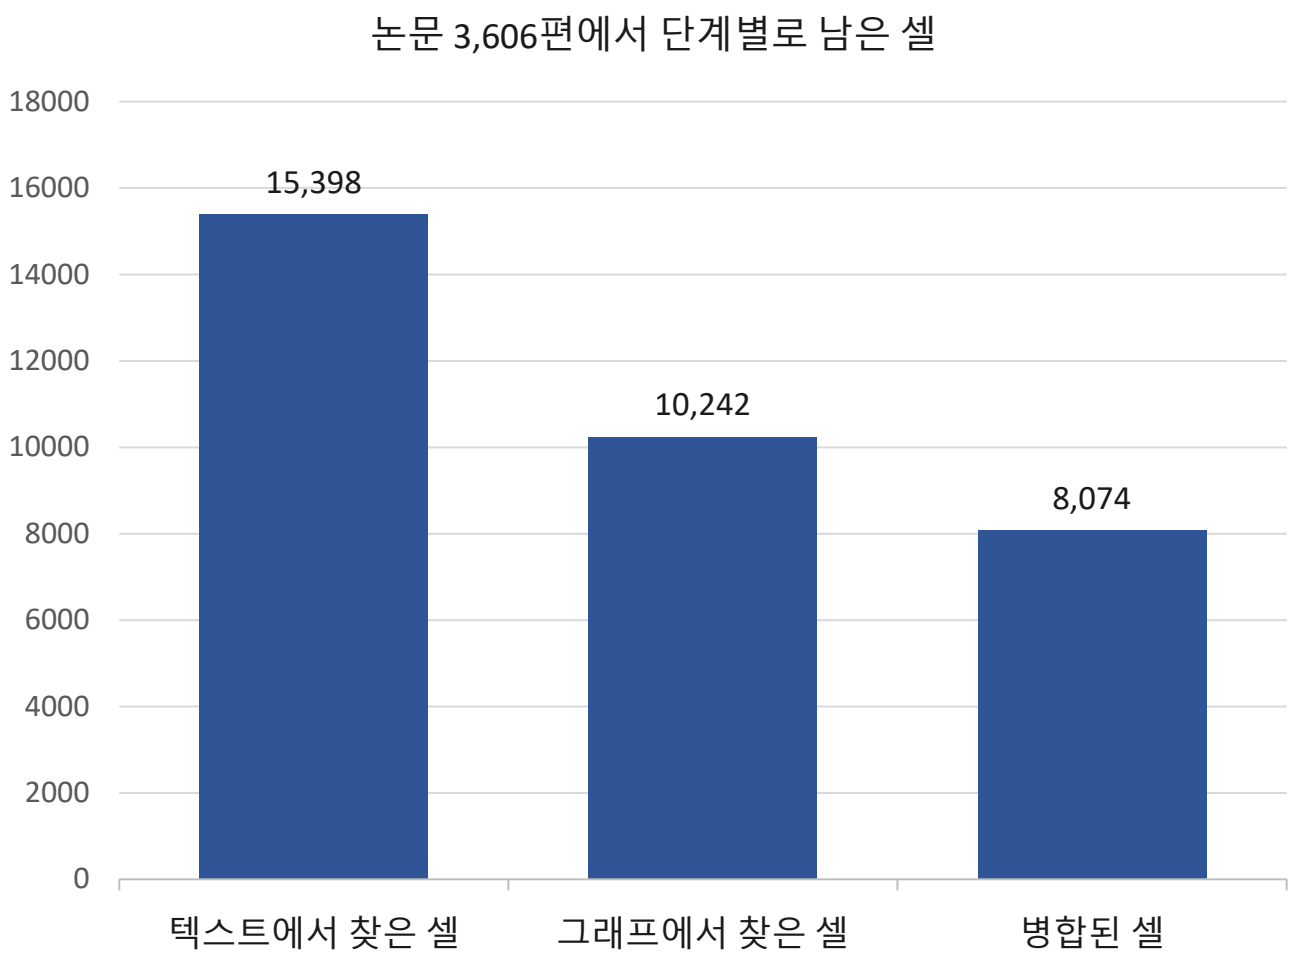
Final Result


```
{'6_a': [{'name_cell': 'PMTFPS-Li anode and S cathode Battery',
   'cathode': {'S cathode with 1.5 mg/cm2 loading',
        'active_material': {'material': ['S'],
        'ratio_of_active_material': [1]},
        'conductive_additive': 'carbon black',
        'binder': 'LA133',
        'ratio_of_cathode_weight': [0.8, 0.1, 0.1],
        'area loading of active material': {'value': 1.5, 'unit': 'mg cm-2'}},
   'electrolyte': {'name_electrolyte': '0.6 mol/L lithium bis(trifluoromethane sulfonyl) imide (LiTFSI) in 1,3-dioxolane (DOL)/dimethoxymethane (DME) (1:1
                       in volume) with 0.4 mol/L LiNO3',
        'Li_salt': {'material': ['LiTFSI', 'LiNO3'],
        'concentration': [0.6, 0.4],
        'unit': ['mol/L', 'mol/L']},
        'solvent': {'material': ['DOL', 'DME'],
        'solvent_volume_ratio': [1, 1],
        'unit': ['v', 'v']},
        'EA_ratio': None},
   'anode': {'name_anode': 'PMTFPS-Li anode',
        'thickness': None,
        'unit': None,
        'additional_layer': 'PMTFPS'},
   'separator': {'name_separator': 'Celgard 2400',
        'separator_material': ['polypropylene']},
   'current_collector': {'collector1': 'Al foil', 'collector2': None},
   'interlayer': None,
   'measurement_condition': {'C_rate': [0.2],
        'current_density': {'value': None, 'unit': None},
        'temperature': {'value': None, 'unit': None}}},
  {'name_cell': 'Bare Li anode and S cathode Battery',
   'cathode': {'name_cathode': 'S cathode with 1.5 mg/cm2 loading',
        'active_material': {'material': ['S'], 'ratio_of_active_material': [1]},
        'conductive_additive': 'carbon black',
        'binder': 'LA133',
        'ratio_of_cathode_weight': [0.8, 0.1, 0.1],
        'area loading of active material': {'value': 1.5, 'unit': 'mg cm-2'}},
   'electrolyte': {'name_electrolyte': '0.6 mol/L lithium bis(trifluoromethane sulfonyl) imide (LiTFSI) in 1,3-dioxolane (DOL)/dimethoxymethane (DME) (1:1
                       in volume) with 0.4 mol/L LiNO3',
        'Li_salt': {'material': ['LiTFSI', 'LiNO3'],
        'concentration': [0.6, 0.4],
        'unit': ['mol/L', 'mol/L']},
        'solvent': {'material': ['DOL', 'DME'],
        'solvent_volume_ratio': [1, 1],
        'unit': ['v', 'v']},
        'EA_ratio': None},
   'anode': {'name_anode': 'Bare Li anode',
```




- 배터리 셀의 모든 정보 수집
- 2-4 분/paper

LLMB가 모은 것



텍스트 추출 F1 0.964–0.990

Cell, 양극, 음극, … 모두 0.95 이상의 높은 정확도

텍스트–그래프 병합 F1 0.993

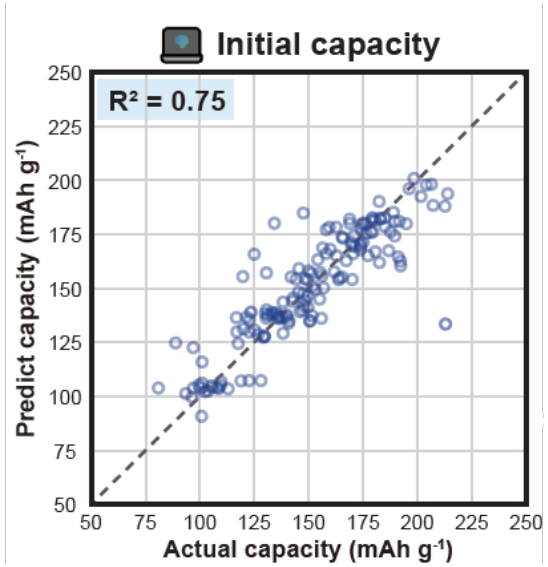
Caption–셀 이름 매칭: LLM 활용 -> 검증

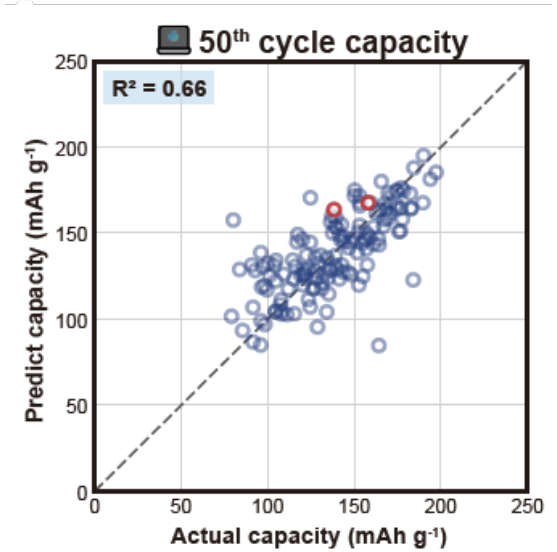
$$\text{Precision: } \frac{TP}{TP + FP} \qquad \text{Recall: } \frac{TP}{TP + FN} \qquad \text{F1: } 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

T: True, F: False, P: Positive, N: Negative

Lee, Woo et al., ACS Cent. Sci. 12, 484 (2026), Table 1

데이터 분석 및 실험 검증





예측

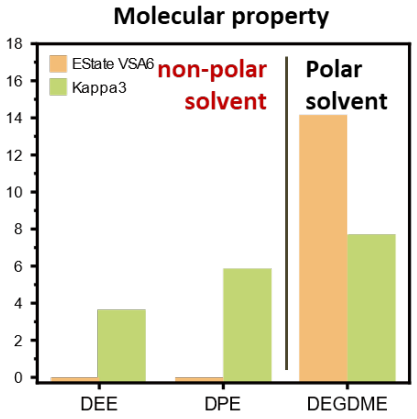
초기 용량: R^2 = 0.75,
50번째 사이클: R^2 = 0.66

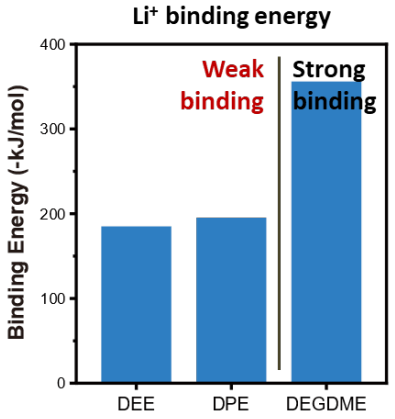
해석

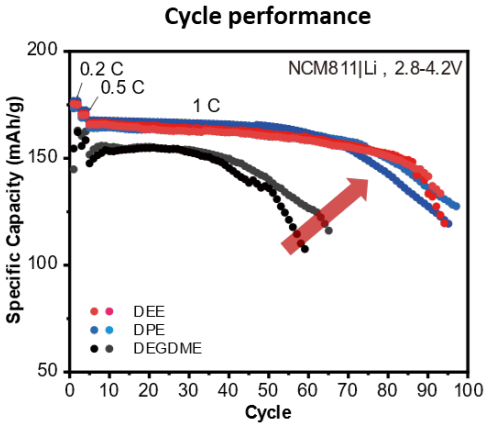
SHAP 상위 특징: 용매 descriptor (EState_VSA6, Kappa3)
-> 약용매화 전해질 우세

실험 검증

약용매화 DEE·DPE → 음이온 유래 SEI(8–9 nm) → 안정적인 사이클

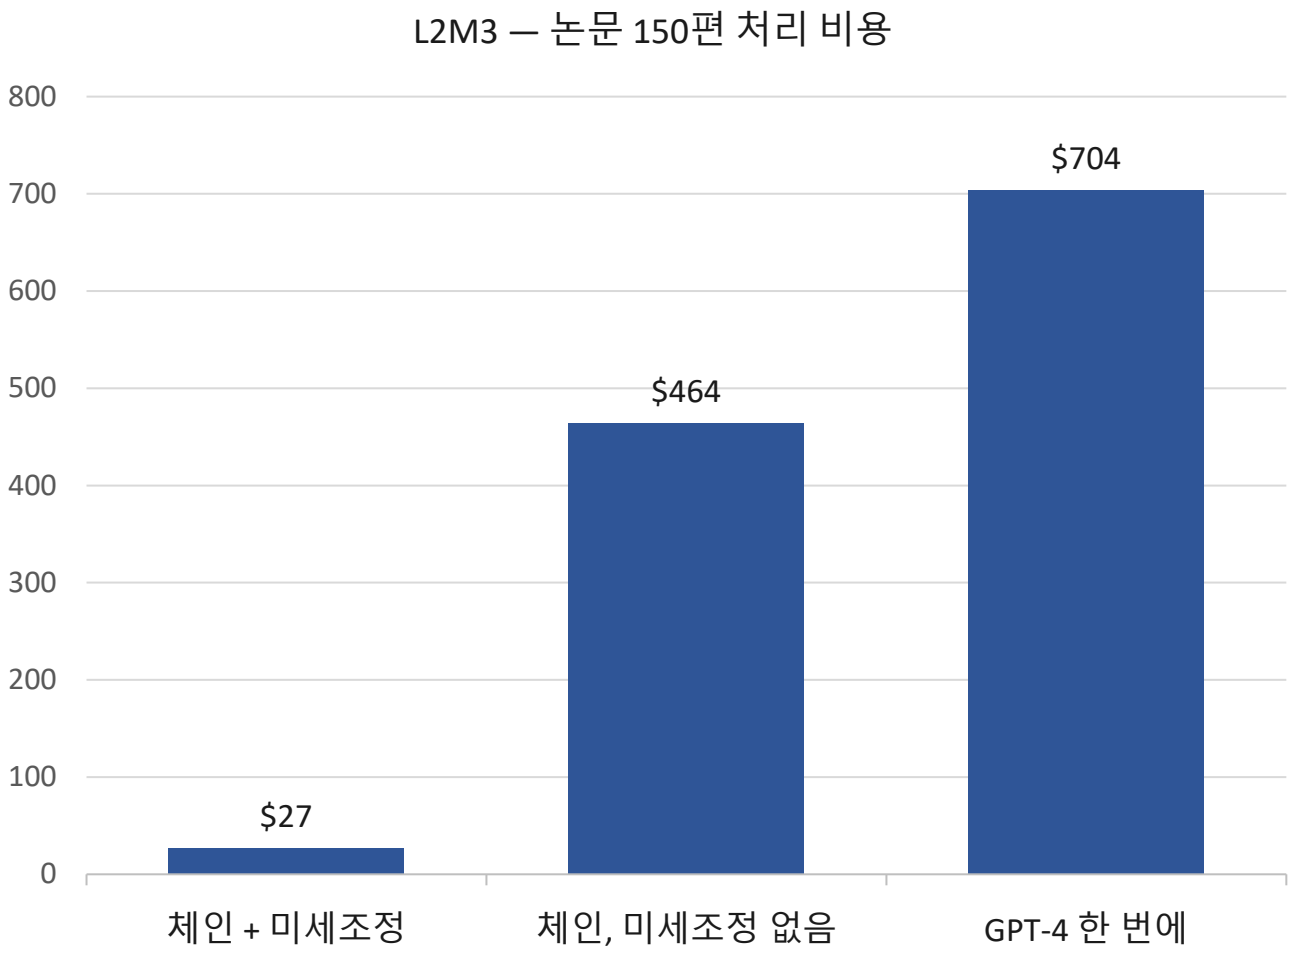






Lee, Woo et al., ACS Cent. Sci. 12, 484 (2026)

Challenge: Verification of the model



가격은 점점 감소

검증은 아직 사람의 일

논문 한편 최소 20분

평가와 검증이 병목

Kang et al. 2025, SI · Gupta et al., Commun. Mater. 5, 269 (2024) · Ghosh & Tewari, Comput. Mater. Sci. 265, 114521 (2026)

Break

논문 지식에 질문하고 근거와 함께 답하기

문헌을 활용하는 방법: 추출, 검색

	데이터 마이닝 (추출)	**RAG · GraphRAG (검색)**
언제	데이터 활용 전	필요할 때마다
결과	구조화된 표 (레코드)	근거가 붙은 답
좋은 질문	모든 셀의 100사이클 용량 분포는?	이 논문의 사이클 조건은? / 논문들이 쓰는 전략은?
강점	통계, ML 학습, 재현 가능한 수치	스키마 없이 무엇이든 질문
한계	스키마에 없는 정보는 없음	답이 매번 다름, 검색 놓치면 오답

LLM에게 그냥 물으면 안 되는 이유

질문
A 논문에서 DEE 전해질의 SEI 두께는?

LLM 단독
약 20 nm입니다.
← 그럴듯하지만 근거 없음

RAG
8–9 nm로 보고됨 [A, Fig. 6 설명 문단].
← 찾은 문단 인용

- **학습 시점 이후 확인 불가**
- **출처의 부재**

  인용 형식이지만 실제 문헌이 아닐 수 있음
- **먼저 찾고, 찾은 근거로 답하기**

  = RAG
- **찾기 위한 문서 구조가 핵심**

검색 증강 생성 (Retrieval-Augmented Generation, RAG)



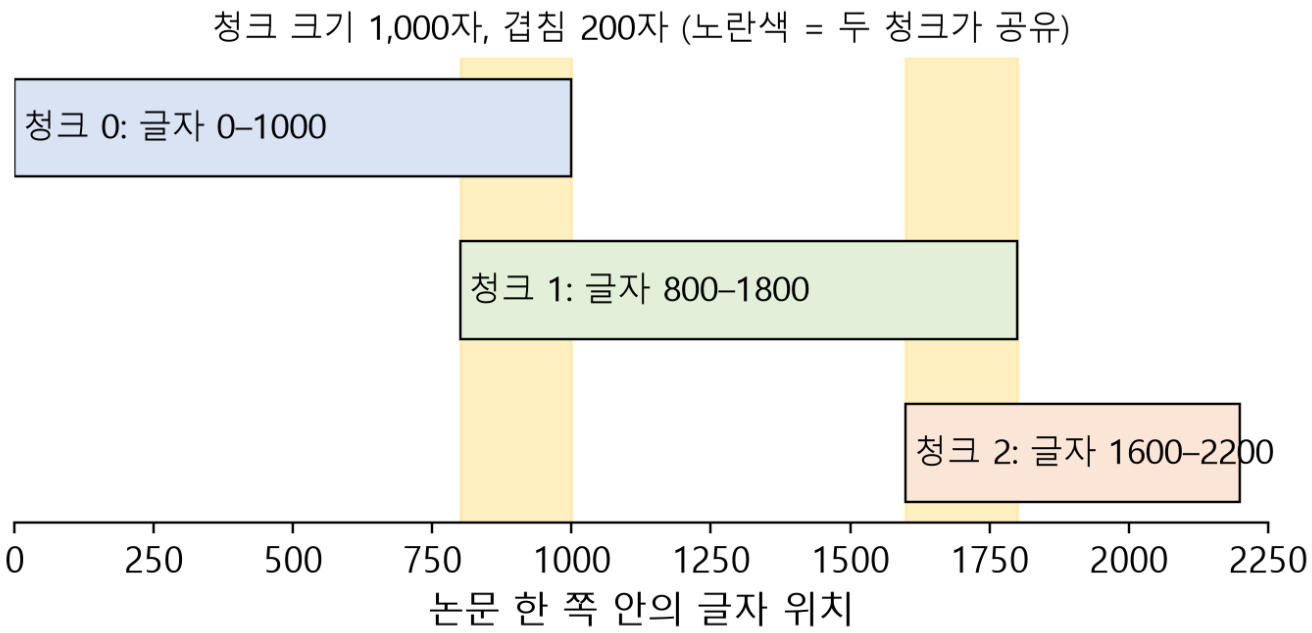
색인 (한 번)
논문 → 청크 → 벡터 → 저장

검색 + 생성 (질문마다)
질문 → 벡터 → 가까운 청크 → 답

모델은 그대로
지식은 모델 밖에, 답할 때 넣어 줌

Lewis et al., Advances in Neural Information Processing Systems 33 (2020)

Chunking: 논문을 조각으로 나누기



v 3. 청킹

```
chunks = split(pages, size=1000, overlap=200)
show_chunks(pages, chunks)
```

Why?

논문 전체 입력은 비싸고, 긴 입력의 중간은 놓치기 쉬움

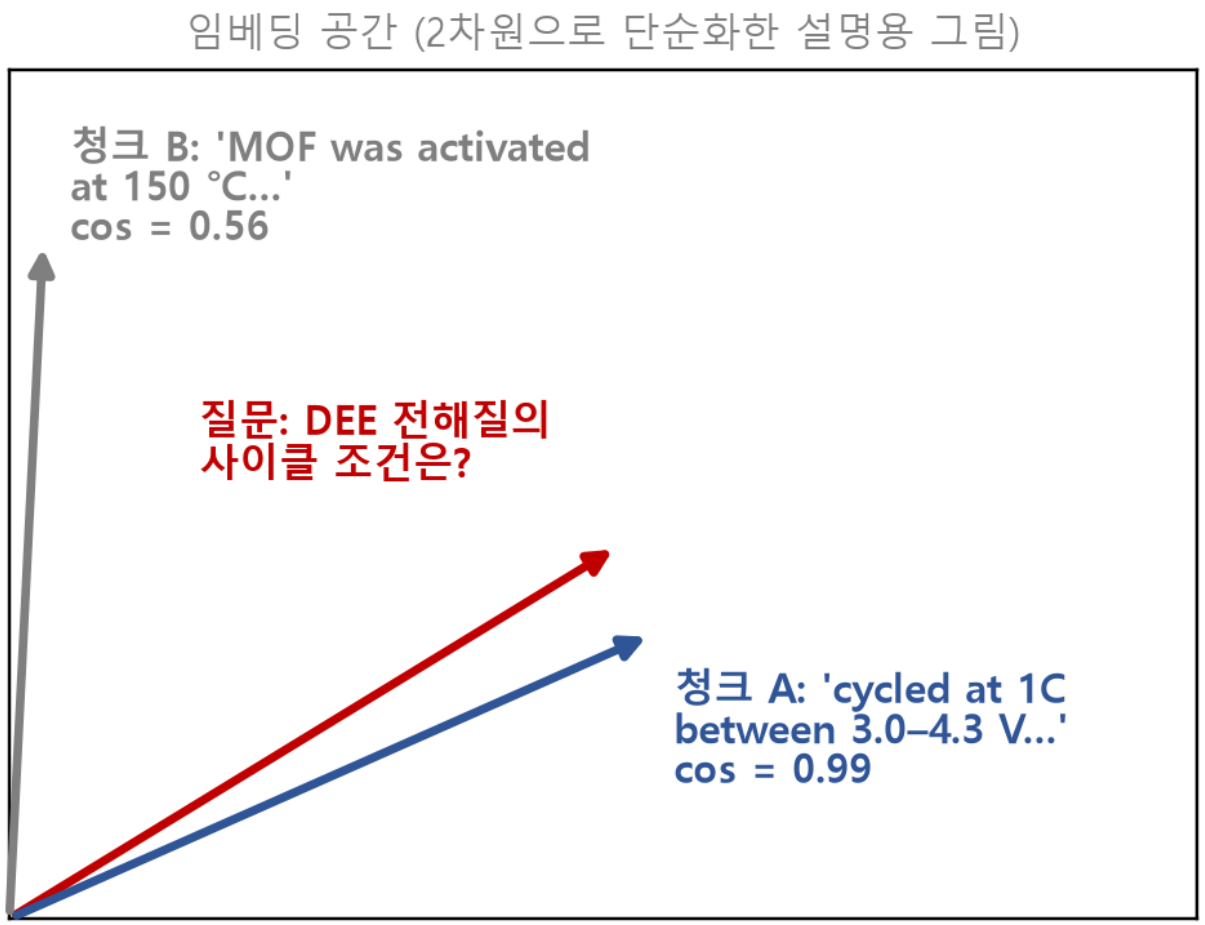
겹침

노란 부분 = 두 청크가 공유 → 경계 문장 보존

너무 작으면

조건(77 K)과 값(1,250 m^2/g)이 다른 청크로 분리

임베딩과 코사인 유사도



같은 모델로 벡터 변환

질문, Chunk: 모두 수백–수천 차원 벡터

$$\cos(q, c) = q \cdot c / (|q| \times |c|)$$

q: 질문 벡터, c: 청크 벡터

상위 k개를 근거로

가장 가까운 청크 몇 개를 프롬프트에 입력

코사인 점수 높음 = 의미가 비슷함

소재 연구에서의 RAG

시스템	검색 대상	하는 일
PaperQA2 (2024, 프리프린트)	논문 전문	논문 검색·읽기 → 인용과 함께 답, 논문 간 모순 탐지
LLaMP (2024, 프리프린트)	Materials Project API	계산 DB를 도구로 호출해 물성 질문에 답
ChatMOF (Nat. Commun. 2024)	MOF 데이터베이스와 ML 모델	MOF 물성 검색·예측·생성
L2M3 + ChatMOF (JACS 2025)	L2M3가 만든 합성 DB	MOF 검색 후 문헌 합성 조건까지 조회

1부에서 만든 DB → 2부의 검색 대상

Skarlinski et al., arXiv:2409.13740 · Chiang et al., arXiv:2401.17244 · Kang & Kim, Nat. Commun. 15, 4705 (2024) · Kang et al., JACS 147, 3943 (2025)

기존 RAG가 실패하는 일곱 지점

실패 지점	무엇이 잘못되나	소재 논문에서의 예
Missing Content	답이 문서에 없음	SI에만 있는 합성 조건
Missed Top Ranked	답이 있는 청크가 상위 k개 밖	'사이클 조건'과 다른 단어로 쓴 문단
Not in Context	찾았지만 프롬프트에서 누락	길이 제한으로 잘린 표
Not Extracted	넣었지만 답에 미반영	SI에 있는 측정 온도
Wrong Format	형식 지시 위반	표 대신 서술로 답함
Incorrect Specificity	너무 일반적이거나 너무 세부적	전략을 물었는데 수치만 답함
Incomplete	일부만 답함	논문 5편 중 2편만 언급

흩어진 정보를 모아야 하는 연결된 질문에 약함 → **GraphRAG**

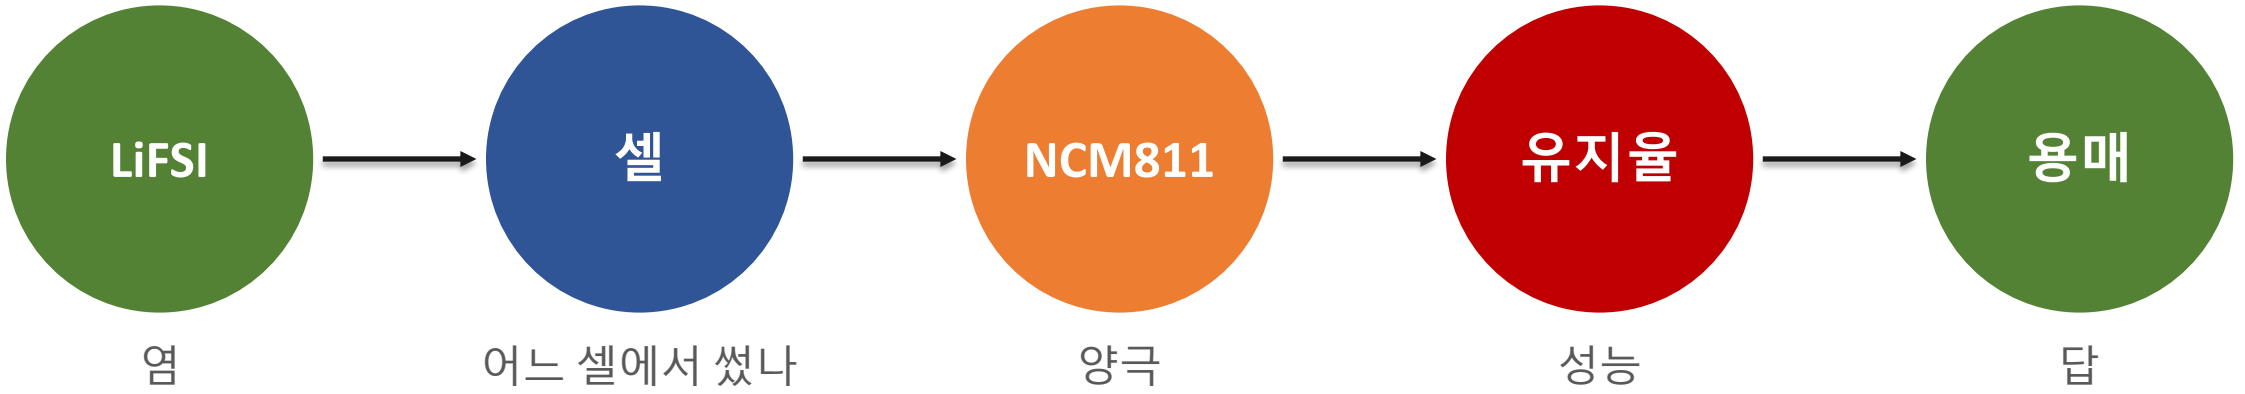
Barnett et al., IEEE/ACM CAIN (2024)

Knowledge Graph & GraphRAG

정보를 연결해서 답하기

연구자의 질문은 여러 단계를 건넌다

"LiFSI를 쓴 전해질 중, NCM811 양극에서 100사이클 유지율이 가장 높은 용매는?"



Multi-Hope Question

답이 한 문단에 없음

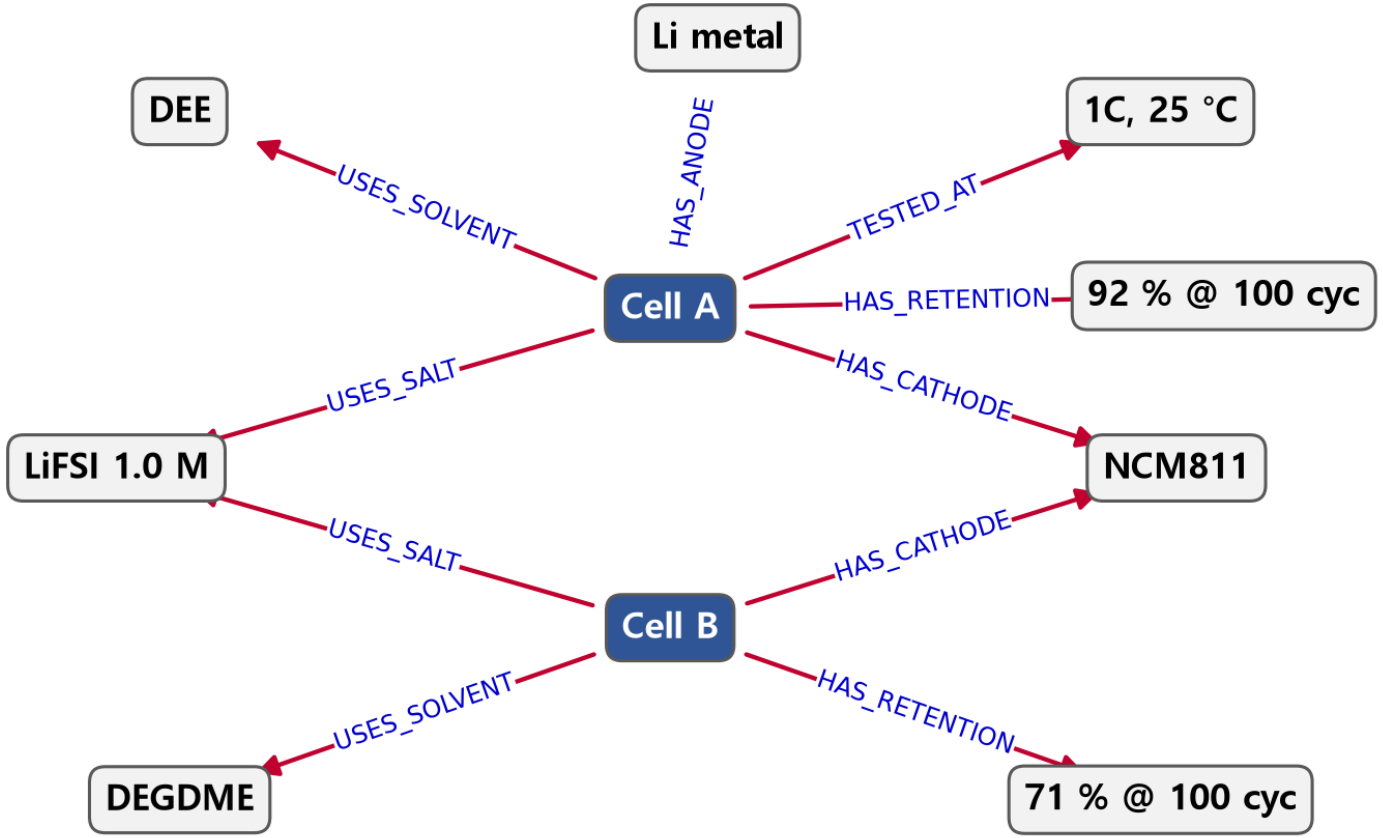
염: 실험 방법 문단 / 양극: 셀 조립 문단 / 유지율: 그림, 논문도 여러 편

기존 RAG: 비슷한 문단 검색뿐

'LiFSI'와 비슷한 문단 5개를 가져와도 연결은 LLM이 짐작

연결을 따라가려면 연결부터 저장 → 그래프

지식 그래프: 노드와 관계



노드 = 개체 또는 값

셀, 전해질, 양극, 조건, 용량

관계 = 이름 붙은 연결

USES_SOLVENT, HAS_CATHODE, HAS_RETENTION

같은 개체를 합치면 연결

Cell A, Cell B: LiFSI·NCM811로 연결, 용매만 다름

표가 잘하는 것

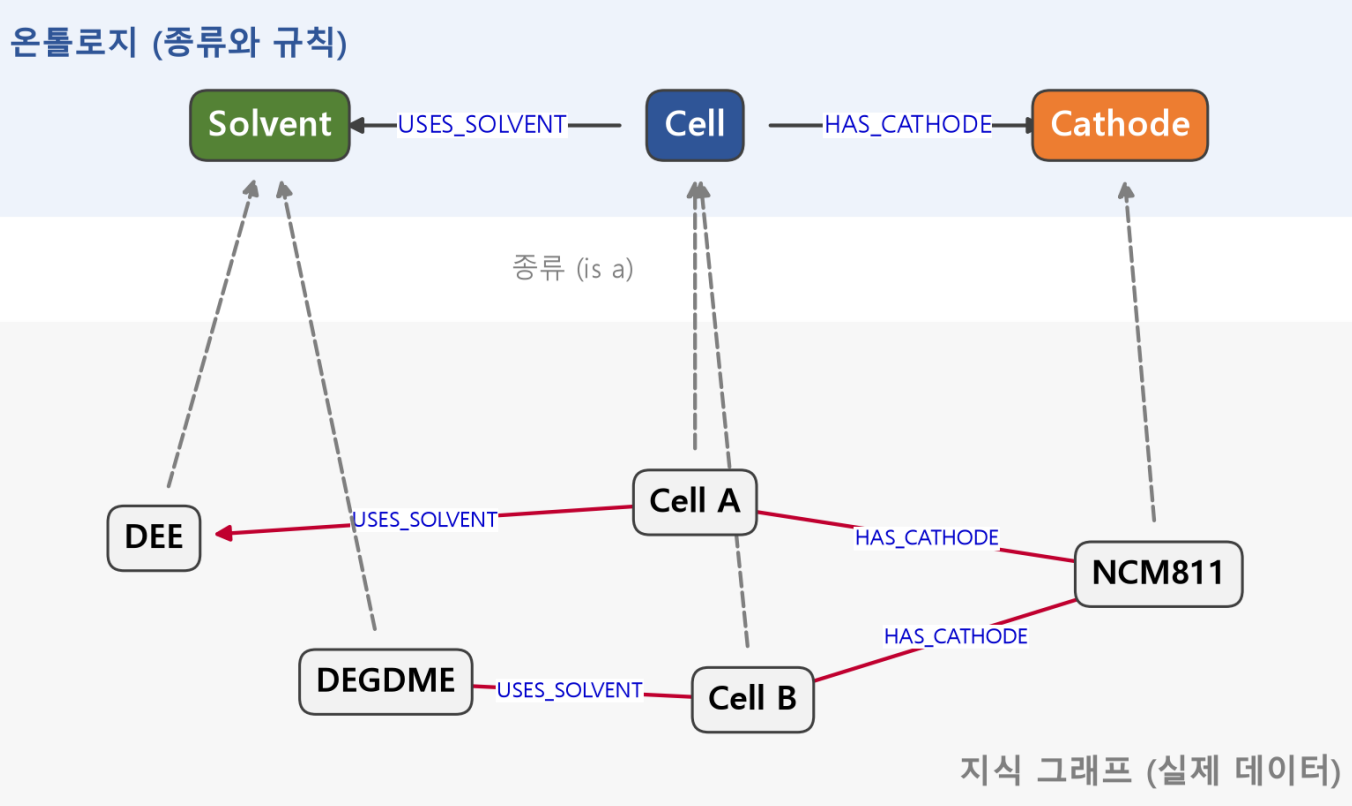
한 셀의 조건·성능, 전체 유지율 분포 같은 통계

표가 못하는 것

빨간 칸 세 개 = 같은 물질(DEE), 표는 모름 → 행 사이·논문 사이 연결은 표 밖

그래프 = 레코드 사이의 연결

온톨로지: 무엇을 노드로, 어떤 관계를 허용할지 정한 약속



노드의 종류 (클래스)

Cell, Salt, Solvent, Cathode, Condition, Performance, Paper

허용된 관계

Cell → USES_SOLVENT → Solvent처럼 어떤 종류끼리 어떤 이름으로 연결할지

실험실 비유

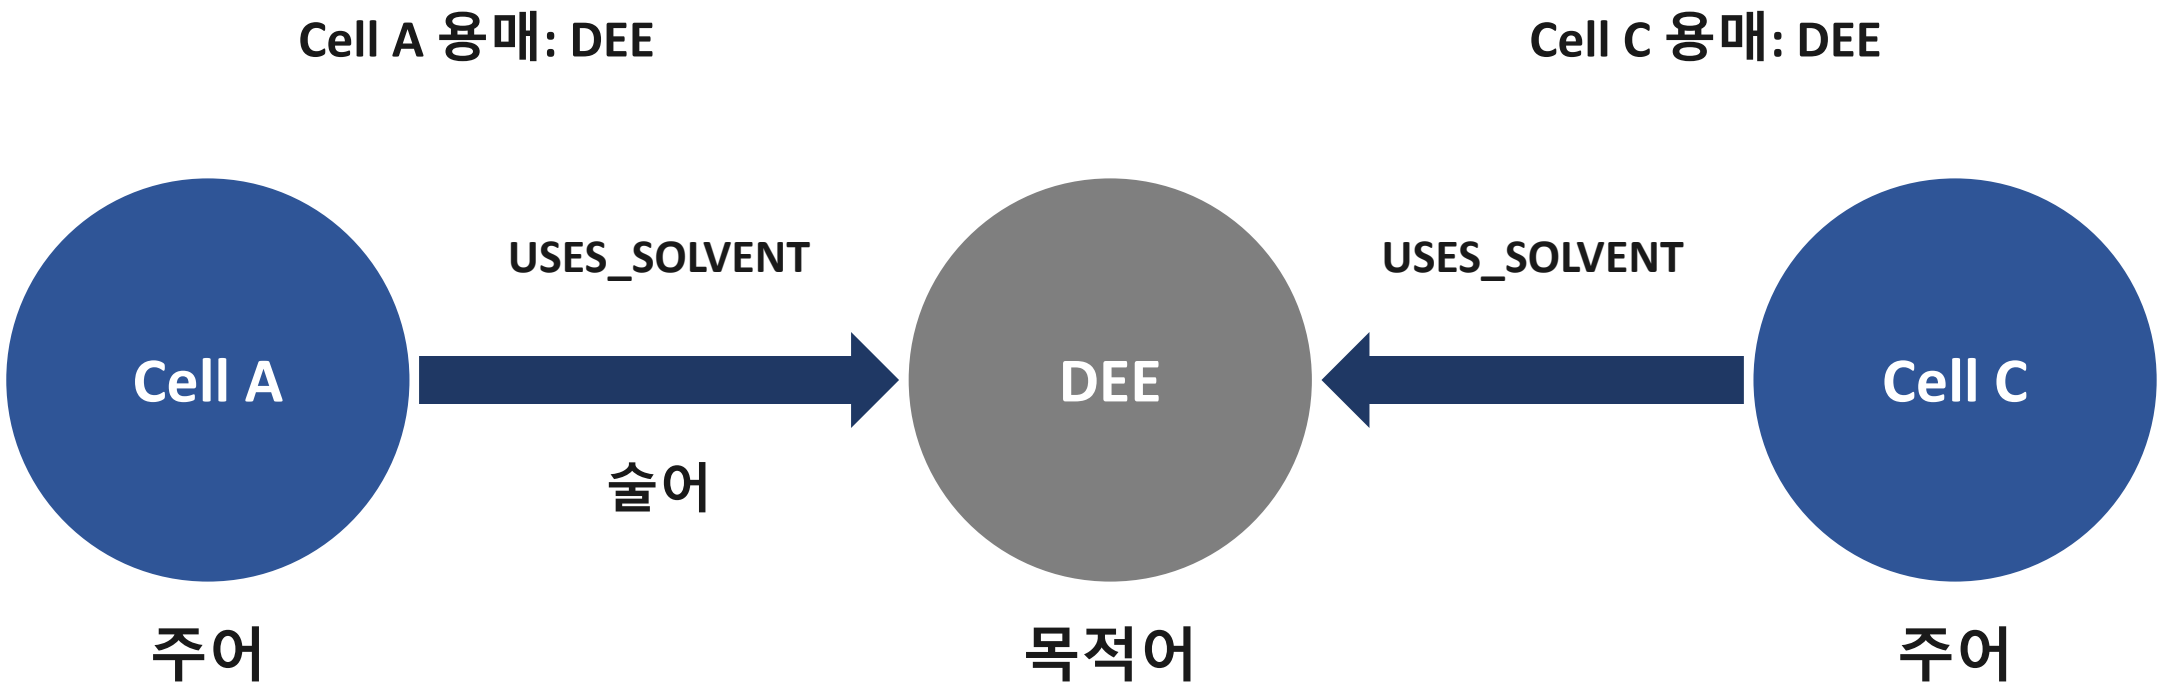
실험 노트 양식: 시료마다 무엇을 어느 칸에 적을지 정한 약속

아래층 관계는 위층 규칙을 따름

Cell A → USES_SOLVENT → DEE: 허용 / DEE → HAS_CATHODE → NCM811: 불허

온톨로지 = 스키마를 '종류'와 '관계'로 정리

트리플: 주어–술어–목적어



다른 논문의 셀이라도 같은 목적어를 공유하면 연결됨

단, 'DEE'와 'diethyl ether'는 같은 노드로 병합 필요 (개체 연결)

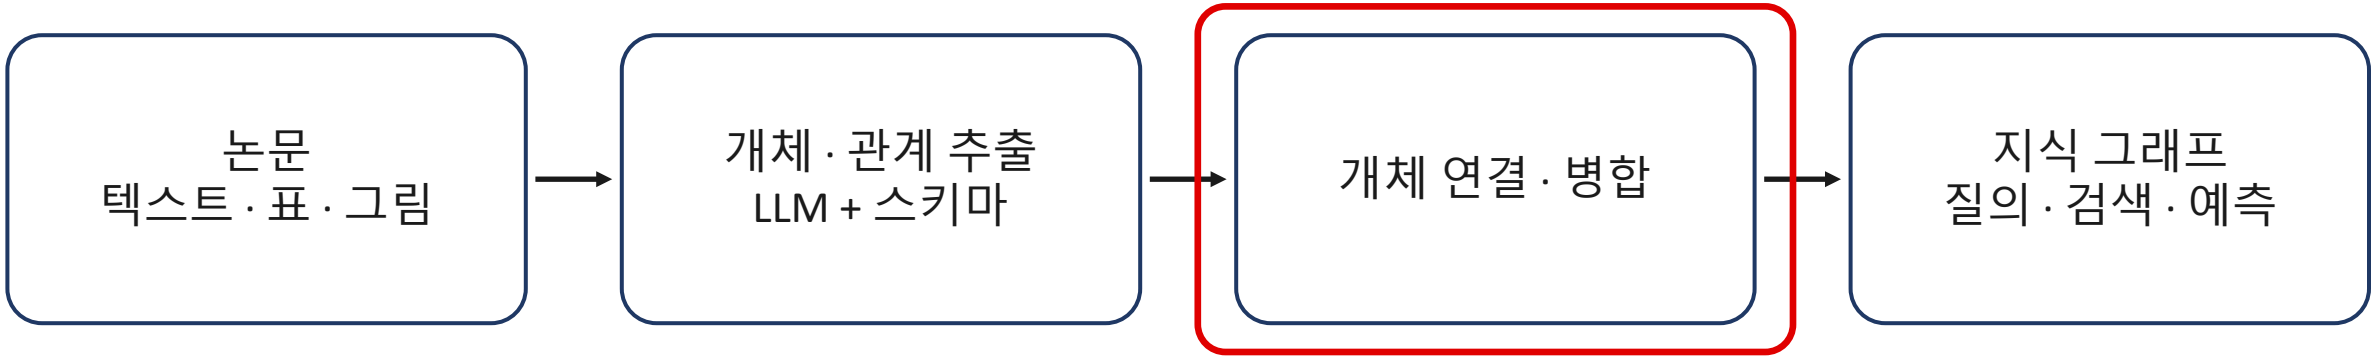
트리플: 주어–술어–목적어

"Cell A was assembled with NCM811 and 1.0 M LiFSI in DEE, and retained 92 % after 100 cycles at 1C."

주어 (Subject)	술어 (Predicate)	목적어 (Object)	목적어의 종류
Cell A	HAS_CATHODE	NCM811	개체 (Cathode)
Cell A	USES_SALT	LiFSI	개체 (Salt)
Cell A	USES_SOLVENT	DEE	개체 (Solvent)
Cell A	SALT_CONCENTRATION	1.0 M	**값 (리터럴)**
Cell A	HAS_RETENTION	92 % @ 100 cyc, 1C	**값 (리터럴)**

- 문장 하나가 트리플 여러 개 가능
- 기존 스키마의 필드 이름이 곧 술어

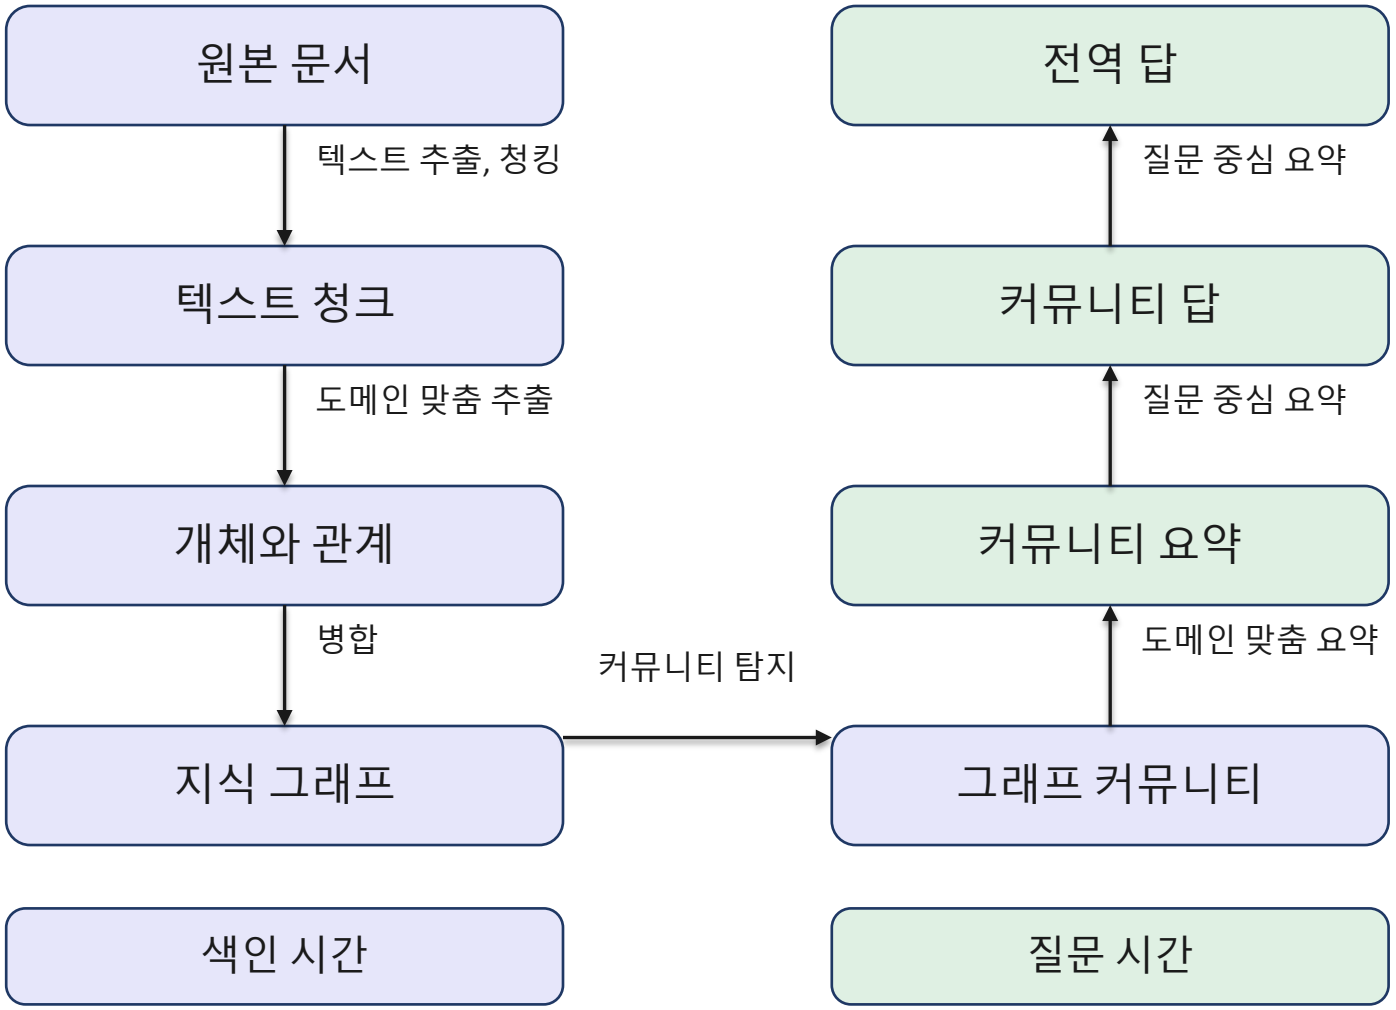
논문 → 지식 그래프



- 같은 물질도 논문마다 다른 이름 → 병합 안 하면 논문별 통합 X
- 분자는 SMILES, 결정은 CSD refcode, 무기물은 화학식 같은 고유한 표기
- MOF-ChemUnity: GPT-4o로 MOF 이름 → CSD 구조 연결 (정확도 94%)
- 모든 관계에 논문·쪽 번호 등 metadata 저장 → 답 추적 가능

Pruyn et al., JACS 147, 43474 (2025) · Bai et al., npj Comput. Mater. 11 (2025)

GraphRAG: 그래프를 색인하고 커뮤니티를 요약



색인 시간 (왼쪽)

청크 → 개체와 관계 → 지식 그래프 → 커뮤니티 → 커뮤니티 요약

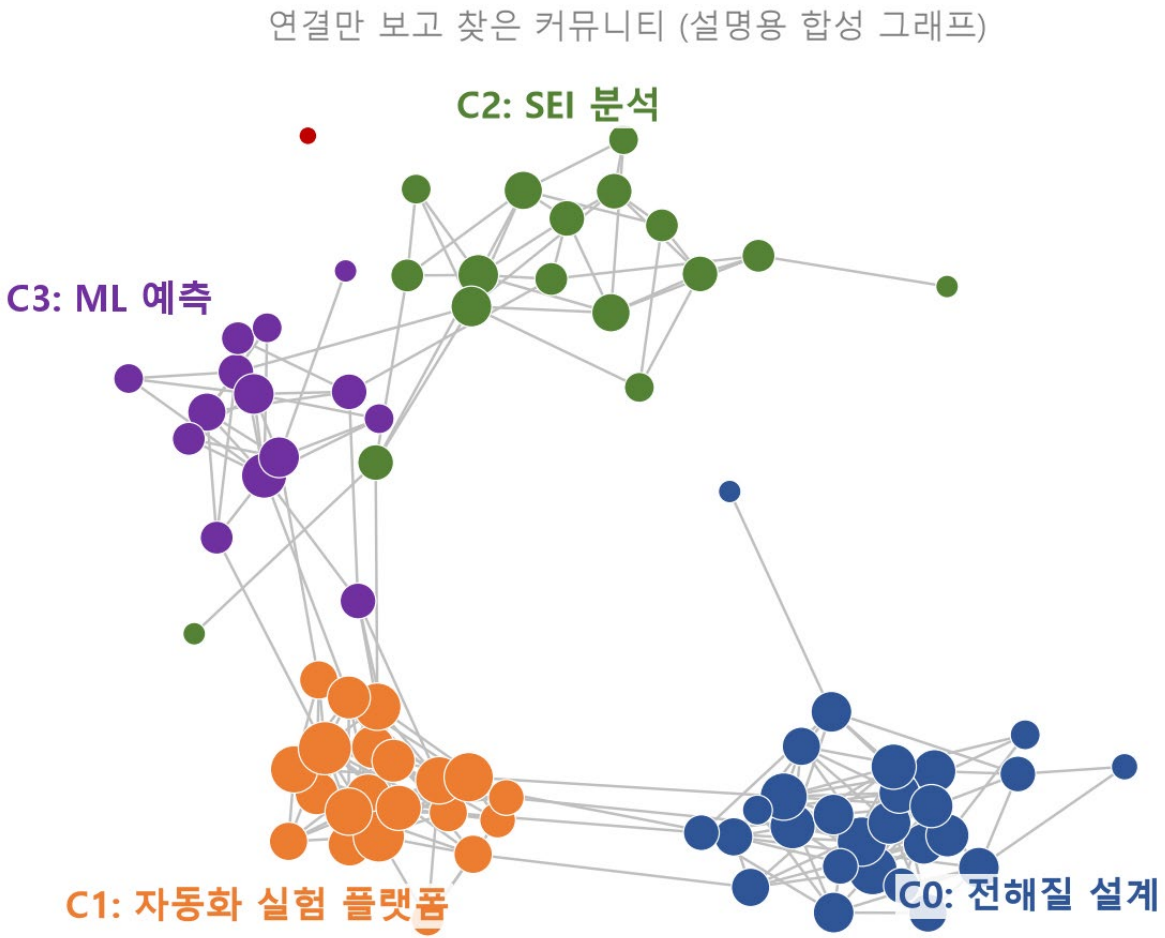
질문 시간 (오른쪽)

커뮤니티 요약마다 부분 답
→ 하나의 전역 답으로 합침

GraphRAG: 흩어진 청크가 아닌 커뮤니티 요약에서 답

Edge et al., arXiv:2404.16130 (2024)

커뮤니티 탐지와 커뮤니티 요약



연결만으로 주제 찾기

촘촘히 연결된 노드 묶음 = 커뮤니티

Leiden 알고리즘

노드 이동 → 분할 정제 → 묶어서 다음 단계, 위로 갈수록 큰 주제

커뮤니티마다 요약

LLM이 제목·요약·핵심 발견 작성 → GraphRAG의 검색 대상은 원문이 아니라 이 요약을 활용

Traag, Waltman & van Eck, Scientific Reports 9 (2019) · Edge et al., arXiv:2404.16130 (2024)

기존 RAG와 GraphRAG 비교

	기존 RAG (벡터 검색)	GraphRAG (커뮤니티 요약)
청크 처리	청크 하나를 벡터 하나로	청크마다 개체와 관계를 여러 개 추출
정보 연결	청크를 따로 저장·검색	같은 개체를 합쳐 청크 사이 연결
준비	청크 벡터 저장	커뮤니티 탐지와 커뮤니티 요약
잘 맞는 질문	몇 개 문단에 있는 구체적 사실	문서 전체에 걸친 주제와 비교
소재 예	이 논문의 사이클 조건은?	이 논문들은 전해질을 어떤 전략으로 개선하나?
한계	근거가 상위 k개에 없으면 누락	추출·병합·요약에서 정보 손실·왜곡
근거 확인	찾은 문단과 답 대조	커뮤니티 요약 → 원 논문까지 추적

Thank You!