

소재 탐색에서의 베이지안 최적화 활용

안광노 Gwang-Noh Ahn

Digital Chemical Research Center
Korea Research Institute of Chemical Technology (KRICT)
gnahn@kRICT.re.kr



Problem


평가의 소모 비용과 시간이 커, '모든 조합'을 돌릴 수 없다



➔ Smart & Sequential design 필요

블랙박스 함수 $f(x)$: 미분 불가, 내부 구조 모름, 평가(실험) 비용 큼


목표: 최적화 $\rightarrow \max_{x \in \mathcal{X}} f(x)$



ex

평가 비용이 높은 ?

! 화학 실험 → 화학 실험은 **본질적으로 최적화 문제**




반응 수율, 선택성, 재료 물성 등 원하는 결과(목표) 극대화

- 온도, 압력, 농도와 같은 **연속형** 매개변수와
- 촉매, 용매, 리간드 유형과 같은 **범주형** 매개변수가 포함

얼마나 최적화가 어려운가?

"차원의 저주(curse of dimensionality)" → 조합 수 폭증 (예: 각 변수 5수준 가정 시)

Variables (d)	Combinations (5^d)
2	25
3	125
4	625
5	3,125
6	15,625
7	78,125
8	390,625




양으로 밀어붙이는 방식: 최적화나 탐색 문제에서 **가능한 모든 경우를 전부 시도해 보는 방법**

단일 요인 변경법

(One-Factor-at-a-Time, OFAT)



- 다른 변수 고정, 한 번에 하나의 변수만 최적화
- 변수들 간 상호작용 무시 (예: 특정 반응 최적 온도는 사용 용매에 의존)
- 전역 최적점(global optimum)을 놓칠 위험 큼 / 최적화에 많은 비용



요인 설계법 및 반응표면분석법

(Factorial Design & Response Surface Methodology, RSM)

- DoE(실험계획법)에 기반한 **통계적 접근법**
- 변수 간 상호작용(interaction) 모델링 가능
- 매개변수 공간 샘플링 → 최적이지 아닌 영역에도 많은 실험 낭비




랜덤 서치 (Random Search)

- 랜덤 서치는 종종 블랙박스 문제에 효율적
- 불필요한 탐색 반복 가능


정적 학습 → 순차적(능동적, 적응적) 학습으로의 전환

Static (RSMG/Grid Search)



- 정적(static), 일회성(one-shot)
- 전체 실험 계획을 사전에 정의
- 유망하지 않은 영역에도 많은 자원 낭비
- 병렬 실행 가능하지만, 적응성 없음


Sequential (Bayesian Optimization)



- 순차적(sequential), 적응적(adaptive)
- 실험 → 모델 업데이트 → 다음 점 제안 → 반복
- 능동적 학습(active learning)
- “실행하며 학습(learn-as-you-go)”
- 더 똑똑하게 실패, 더 빠르게 학습, 더 적은 자원
- 샘플 효율성↑, 비효율적 탐색 방지



어떻게 활용될까?


재료연구에서 자동화 시스템과 좋은 궁합 → **SDL (자율주행연구실)**



예시 BO 기반 초고속 흐름 화학 플랫폼

- ✓ 초고속 화학(Ultrafast chemistry) : 매우 짧은 수명(수-ms)의 중간체 제어 기술
 - 온도, 유량, 반응기 부피, 유기리튬 종 등의 다양한 변수 정밀제어 필요
 - 시간·노동 소모, 숙련된 전문가 필요






베이지안 최적화

- 확률적 모델(Gaussian process)로 **파라미터 효율적 탐색**
- 획득 함수(기대 개선)로 **탐색과 착취의 균형 조절**
- 튜닝 과정에서 적은 실험으로 최적 제어 상수를 찾음

ParBayesianOptimization in Action (Round 1)



베이지안 최적화의 구성요소 1 : 대리모델 (Surrogate Model)

대리모델(Surrogate Model)이란?

비싼 실험 $f(x)$ 을 값싼 기계학습 모델 $f^{\wedge}(x)$ 로 근사 $\rightarrow$ 탐색·의사결정을 돕는 모델

다양한 회귀모델 활용 가능


- 가우시안 프로세스(GP): 불확실성 우수
- 랜덤포레스트/트리: 범주·비선형 강함
- XGBoost: 과적합 억제
- TPE: 혼합공간에 강함
- SVR: 경계 선명 회귀
- 베이지안 회귀: 사후분포 제공
- 베이지안 신경망: 표현력+불확실성
- 폴리노미얼/RBF: 간단·빠른 근사
- 크리깅(Kriging): 공학 분야 전통
- 멀티피델리티 GP: 저비용데이터 활용

⋮



너무 많은데 어떤 것을 선택?
 $\rightarrow$ 벤치마킹

Surrogate Model



GP는 함수에 대한 확률 분포를 정의
최적점을 찾기 위해 목표 함수를 탐색

- 초기 데이터 포인트를 기반 GP는 확률적 지도를 만들며
이 지도는 미탐색된 모든 지점 x 에 대해 두 가지 핵심 정보를 제공

출력

- 예측값 $\mu(x)$: 그 지점의 기대 성능
- 불확실성 $\sigma(x)$: 예측 신뢰도(데이터 가까이↓, 먼 곳↑)

$$\mu(\lambda) = \mathbf{k}_*^T \mathbf{K}^{-1} \mathbf{y}, \sigma^2(\lambda) = k(\lambda, \lambda) - \mathbf{k}_*^T \mathbf{K}^{-1} \mathbf{k}_*$$

- 반복되는 실험에 따라 더 많은 데이터 포인트를 추가
➡ GP 모델은 업데이트되어 실제 함수를 더 정확하게 표현하게 되고 불확실성은 감소



$$\mu(\lambda) = \mathbf{k}_*^T K^{-1} \mathbf{y}, \quad \sigma^2(\lambda) = k(\lambda, \lambda) - \mathbf{k}_*^T K^{-1} \mathbf{k}_*$$

$\mu(\lambda)$: 평균 예측값

- $\mathbf{k}_*$: 예측하려는 점과 기존 데이터 간의 유사도 (커널 값 벡터)
- K^{-1} : 기존 데이터의 상관관계 행렬을 반영
- $\mathbf{y}$: 실제 관측 데이터 값

$\sigma^2(\lambda)$: 예측 불확실성(분산)

- 데이터와 가깝다면 σ^2 가 작아지고 (확신 $\uparrow$)
- 데이터와 멀면 커져요 (불확실성 $\uparrow$)

(1) 일반적인 Matérn 커널

$$C_\nu(\lambda, \lambda') = \sigma^2 \frac{2^{1-\nu}}{\Gamma(\nu)} \left(\frac{\sqrt{2\nu} d(\lambda, \lambda')}{\rho} \right)^\nu K_\nu \left(\frac{\sqrt{2\nu} d(\lambda, \lambda')}{\rho} \right)$$

- $d(\lambda, \lambda')$: 두 점 사이의 거리
- ρ : 길이 스케일 (데이터 간 얼마나 떨어져야 독립적이라고 볼지)
- ν : 커널의 매끄러움 정도를 조절하는 파라미터
- K_ν : 베셀 함수 (수학적 형태, 세부는 몰라도 됨)

(2) Matérn 5/2 커널 (자주 쓰이는 버전)

$$C_{5/2}(\lambda, \lambda') = \left(1 + \sqrt{5}d + \frac{5}{3}d^2 \right) \exp(-\sqrt{5}d)$$

- 여기서 $d = d(\lambda, \lambda')$.
- 이 식은 "매끄럽지만 너무 뾰뾰하지 않은" 함수 모양을 만들어 줘서, 실제 데이터 예측에서 자주 사용 돼요.

베이지안 최적화의 구성요소 2 : 획득 함수 (Acquisition Function)

대리모델(지도)의 예측값 $\mu(x)$ 과 불확실성 $\sigma(x)$ 을 이용해, 다음 실험점 x_{t+1} 을 고르는 규칙

역할

- 전역 최적점을 더 빨리 찾도록 "가장 유용한" 위치 추천
- 정적 계획이 아닌 순차·적응적 설계의 핵심


$$EI(x) = \underbrace{(\mu(x) - f_{\max})\Phi\left(\frac{\mu(x) - f_{\max}}{\sigma(x)}\right)}_{\text{평균이 더 좋게 나올 가능성} \times \text{그 개선량}} + \underbrace{\sigma(x)\phi\left(\frac{\mu(x) - f_{\max}}{\sigma(x)}\right)}_{\text{불확실성}(\sigma)\text{이 커서 '더 좋아질 여지'가 남은 정도}}$$

평균이 더 좋게 나올 가능성 $\times$ 그 개선량


개선확률 Probability of Improvement; 이하 PI

불확실성(σ)이 커서
'더 좋아질 여지'가 남은 정도

- $\Phi()$: 정규분포 누적분포(그 값보다 작을 확률)
- $\phi()$: 정규분포 밀도함수(봉우리 높이)



베이지안 최적화 루프 단계별 분석



질문 : 베이지안 최적화? PID 제어?

베이지안 최적화

목적

파라미터 최적화

방식

확률모델 · 획득 함수


장점

샘플 효율적

단점

구현 복잡

어떤 값을 최적화 (ex. 수율이 최대가 되도록 온도, 유량 등을 조절)



최적화(지도)를 통해
정상을 찾고

(네이버지도 맛집 검색)

PID 제어

목적

조작 변수 정밀 제어

방식

비례 · 적분 · 미분

장점

단순 · 빠른 응답

단점

수동 튜닝 필요

단순 공정 제어 (온도, 유량 그 자체를 정밀 제어, ex 온도 정확히 90도로)



제어(나침반)를 통해
정상에 도달

(네비게이션 길찾기)

질문 : 베이지안 최적화? PID 제어?

PID 제어 원리

현재와 목표값의 차이(오차)를 줄이는 방식으로



P 비례 : 현재 오차를 비례 보정

I 적분 : 누적 오차를 반영해 오차 제거

D 미분 : 오차 변화율 고려 속도 향상

제어 식

$$u(t) = K_p e(t) + K_i \int e(t) dt + K_d \frac{de(t)}{dt}$$




자율 합성 플랫폼용 메타 최적화(MO) 알고리즘 개발 사례

✓ 베이지안 최적화(BO)는 실시간 최적화를 위해 대리 모델(surrogate model)을 생성

→ 수 많은 대리 모델, 타겟 화학에 따라 모델 간 성능 차이 발생

→ 대리 모델을 벤치마킹하여 선정/최적화하는데 비효율 발생 가능





실시간으로 대리모델을 평가, 최적 BO 선택하는 메타 최적화(MO) 기법 개발/도입
다양한 화학 반응에서 일관된 최적화 성능을 제공

자율 합성 플랫폼용 메타 최적화(MO) 알고리즘 개발 사례

- ✓ 최적화 목표: 최대 수율(Goal: Maximum Yield)로 설정하여 성능비교
 - Maximum Yield (최대 수율) 도달 속도 기준으로 비교 (좌측 그래프)
 - 그 외 및 SNR (신호 대 잡음비), AF (가속 계수), EF (향상 계수)를 종합 비교 (우측 그래프)

예시 chemoselective metalation



(위 chemoselective metalation 포함 4종에 대해 검증)

화학 데이터셋 종류에 상관 없이 MO가 최대 수율 달성 속도, SNR, AF, EF 측면에서 다른 BO보다 일관된 최적화 성능

다양한 화학 반응에서 일관된 최적화 성능을 제공하는 새로운 자동화 플랫폼의 가능성을 제시

구글 코랩 활용

Ipynb 파일 : gitlab

https://gitlab.chemdx.org/education/2025-materials-informatics/-/tree/master/week_07

1) Imports & Objective (Branin)

목적: 최적화 대상 함수 정의

Branin 함수 (2D, 여러 전역 최소값 존재)

탐색 범위: $x \in [-5, 10]$ $y \in [0, 15]$

테스트: $\text{branin}([\pi, 2.275]) \approx 0.397887$

→ 우리가 찾을 최소값의 기준점

2) One-line GP Bayesian Optimization

목적: 최적화 대상 함수 정의

gp_minimize로 간단 실행

입력: 목적 함수, 탐색 범위, 평가 횟수(`n_calls`), 초기 랜덤 포인트(`n_initial_points`)
기본적으로 EI(기대 개선) 사용

출력: Best y (최소 함수값) Best x (최적 좌표)

Convergence plot으로 반복 → 수렴 과정 확인

3) Visualization of Sampled Points

Branin 함수 landscape 시각화 (contourf)

탐색 과정에서 선택된 점들 표시

- 흰색 점: 시도된 샘플
- 빨간 점: 최적 해(best)

시각화를 통해 **탐색/수렴 패턴 직관적 이해**

3) Visualization of Sampled Points

Branin 함수 landscape 시각화 (contourf)

탐색 과정에서 선택된 점들 표시

- 흰색 점: 시도된 샘플
- 빨간 점: 최적 해(best)

시각화를 통해 **탐색/수렴 패턴 직관적 이해**

4) Live Monitoring

목적: 최적화 대상 함수 정의

실시간 시각화:

- GP surrogate (평균 μ , 표준편차 σ)
- Acquisition function (EI 맵)

루프 진행 시:

- 샘플 점 하나씩 추가
- Best point 업데이트

결과: 최적화 과정을 시뮬레이션처럼 시각적으로 확인

5) Human-in-the-loop

직접 참여하는 최적화

- 사람이 (x, y) 좌표 제안
- 결과값 $f(x,y)$ 피드백

UI 방식

- 텍스트 입력: 좌표 직접 입력
- 위젯 UI: 슬라이더/버튼으로 조작

비교:

- 내 성과 vs. 랜덤 baseline
- 전역 최소값 (~ 0.397887)과의 차이 확인

6) Exercises

- 실습 확장 아이디어 제시

1. 알고리즘 개선 관련 아이디어 (메타 최적화 같은)
2. 응용/적용 아이디어 (본인 연구에 적용 가능성 탐구)
3. 기타 아이디어?

6) Exercises

- 실습) 함수 branin 함수를 다른 유명한 함수로 바꿔서 수행해보기 (슬라이드)
- 실습) 확장 아이디어 제시
 - 1.알고리즘 개선 관련 아이디어 (메타 최적화 같은) (1-2줄이라도 OK)
 - 2.응용/적용 아이디어 (본인 연구에 적용 가능성 탐구) (1-2줄이라도 OK)

감사합니다

